

Hochschule für Technik
und Wirtschaft Berlin

University of Applied Sciences

Statistik für Wirtschaftsinformatik

Pflichtmodul B3.5
Bachelorstudiengang Wirtschaftsinformatik

Prof. Dr. Martin Spott, Data Science

Kapitel 2

Beschreibung und Exploration eindimensionaler Daten

Beispiel Thema der Diplomarbeit*

Die $k = 4$ verschiedenen Themen der $n = 36$ Diplomarbeiten sind

- 1: Statistik
- 2: Computergrafik
- 3: Computerspiel
- 4: Datenbank

Daten:

Person i	1	2	3	4	5	6	7	8	9	10	11	12
Thema x_i	3	4	4	3	4	1	3	4	3	4	4	3
Person i	13	14	15	16	17	18	19	20	21	22	23	24
Thema x_i	2	3	4	3	4	4	2	3	4	3	4	2
Person i	25	26	27	28	29	30	31	32	33	34	35	36
Thema x_i	4	4	3	4	3	3	4	2	1	4	4	4

* abgeleitet aus Beispiel in [1], Münchner Absolventenstudie

Beschreibung und Exploration eindimensionaler Daten

- Betrachtung eines Merkmals X
  Im Beispiel „Thema der Diplomarbeit“
- Erhebung vom Umfang n
  Im Beispiel wurden $n = 36$ Studierende (Untersuchungseinheiten) befragt
- Beobachtung der Werte $x_1, x_2, \ldots x_n$ für X
  Im Beispiel $x_1 = 3$ (Computerspiel)
- Diese Werte werden als ***Rohdaten,*** *Primärdaten oder* ***Urliste*** bezeichnet.

Häufigkeiten

Welche Werte kommen wie häufig vor?

$x_1, x_2, \ldots x_n$ nehmen k verschiedene Werte $a_1, a_2, \ldots a_k$ mit $k \leq n$ an.

Beispiel: 36 Diplomarbeiten verteilt auf 4 Themen

x_j 3 4 4 3 4 1 3 4 3 4 4 3 2 3 4 3 4 4 2 3 4 3 4 2 4 4 3 4 3 3 4 2 1 4 4 4

x_j sortiert | 1 1 | 2 2 2 2 | 3 3 3 3 3 3 3 3 3 3 3 3 | 4 4 4 4 4 4 4 4 4 4 4 4 4 4 4 4 4 4 |

a_j 1 2 3 4

Strichliste

Welche Werte kommen wie häufig vor?

Thema	Wert/Ausprägung a_i	Anzahl
Statistik	1	||
Computergrafik	2	||||
Computerspiel	3	𝍸 𝍸 ||
Datenbank	4	𝍸 𝍸 𝍸 |||

Anzahl der Ausprägungen

Die Anzahl k verschiedener Werte a_j ist bei

1. qualitativen und diskreten Merkmalen oft deutlich kleiner als
2. stetigen und quasi-stetigen Merkmalen oft [fast] gleich groß wie

die Anzahl n der Merkmalsträger.

Beispiele

- nur 4 Diplomarbeitsthemen bei 36 Studierenden
- nur wenige Automodelle bei Millionen von Kunden
- aber jeden Tag eine andere Temperatur, wenn genau gemessen

Absolute und relative Häufigkeit

Absolute und relative Häufigkeiten

$h(a_j) = h_j$	*absolute Häufigkeit* der Ausprägung a_j, d.h. Anzahl der x_i aus $x_1, \ldots x_n$ mit $x_i = a_j$
$f(a_j) = f_j = h_j/n$	*relative Häufigkeit* von a_j
$h_1, \ldots, h_k$	*absolute Häufigkeitsverteilung*
$f_1, \ldots, f_k$	*relative Häufigkeitsverteilung*

Eine ***Häufigkeitstabelle*** listet die Ausprägungen a_j mit absoluten Häufigkeiten h_j und/oder relativen Häufigkeiten f_j auf.

Beispiel: Thema der Diplomarbeit

Ausprägung	absolute Häufigkeit h	relative Häufigkeit f
1	2	$2/36 = 0.056$
2	4	$4/36 = 0.111$
3	12	$12/36 = 0.333$
4	18	$18/36 = 0.500$

Bessere Darstellungsform als Häufigkeitstabellen?

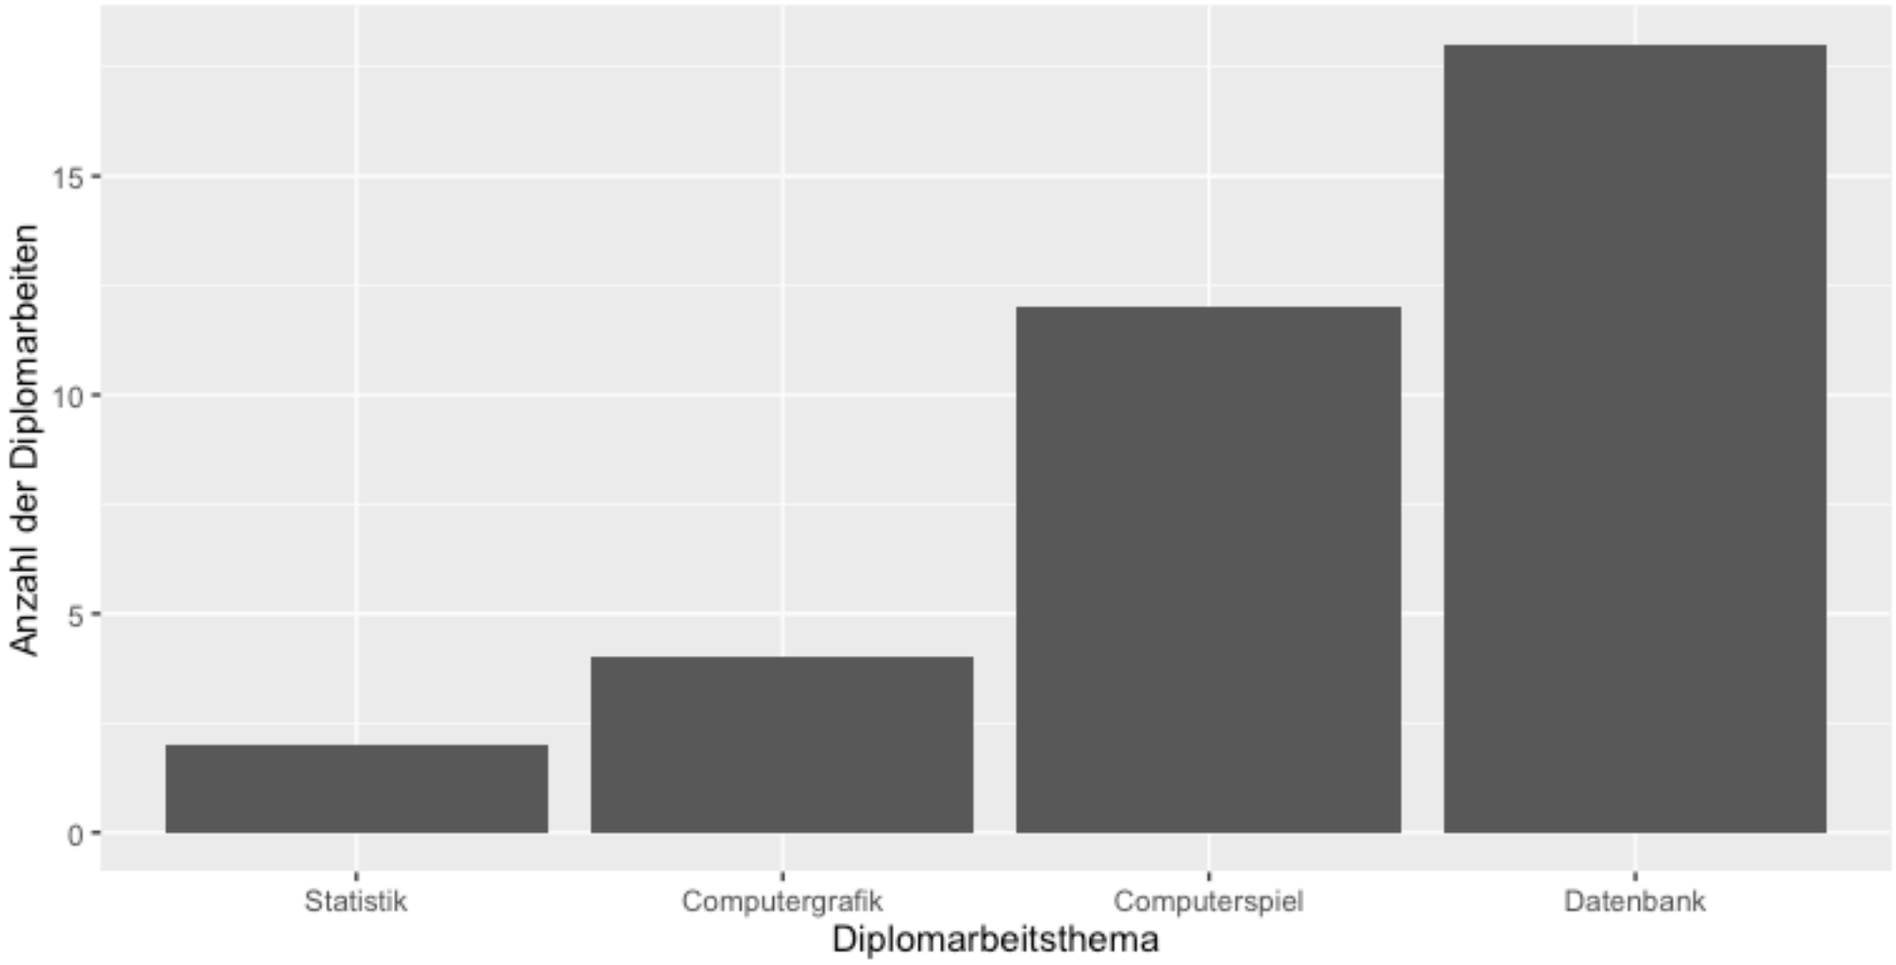
Ausprägung	absolute Häufigkeit h	relative Häufigkeit f
1	2	$2/36 = 0.056$
2	4	$4/36 = 0.111$
3	12	$12/36 = 0.333$
4	18	$18/36 = 0.500$

Grafische Darstellungen

- Balkendiagramme für qualitative Merkmale
  (unter gewissen Bedingungen auch für diskrete)

- Histogramme für quantitative Merkmale

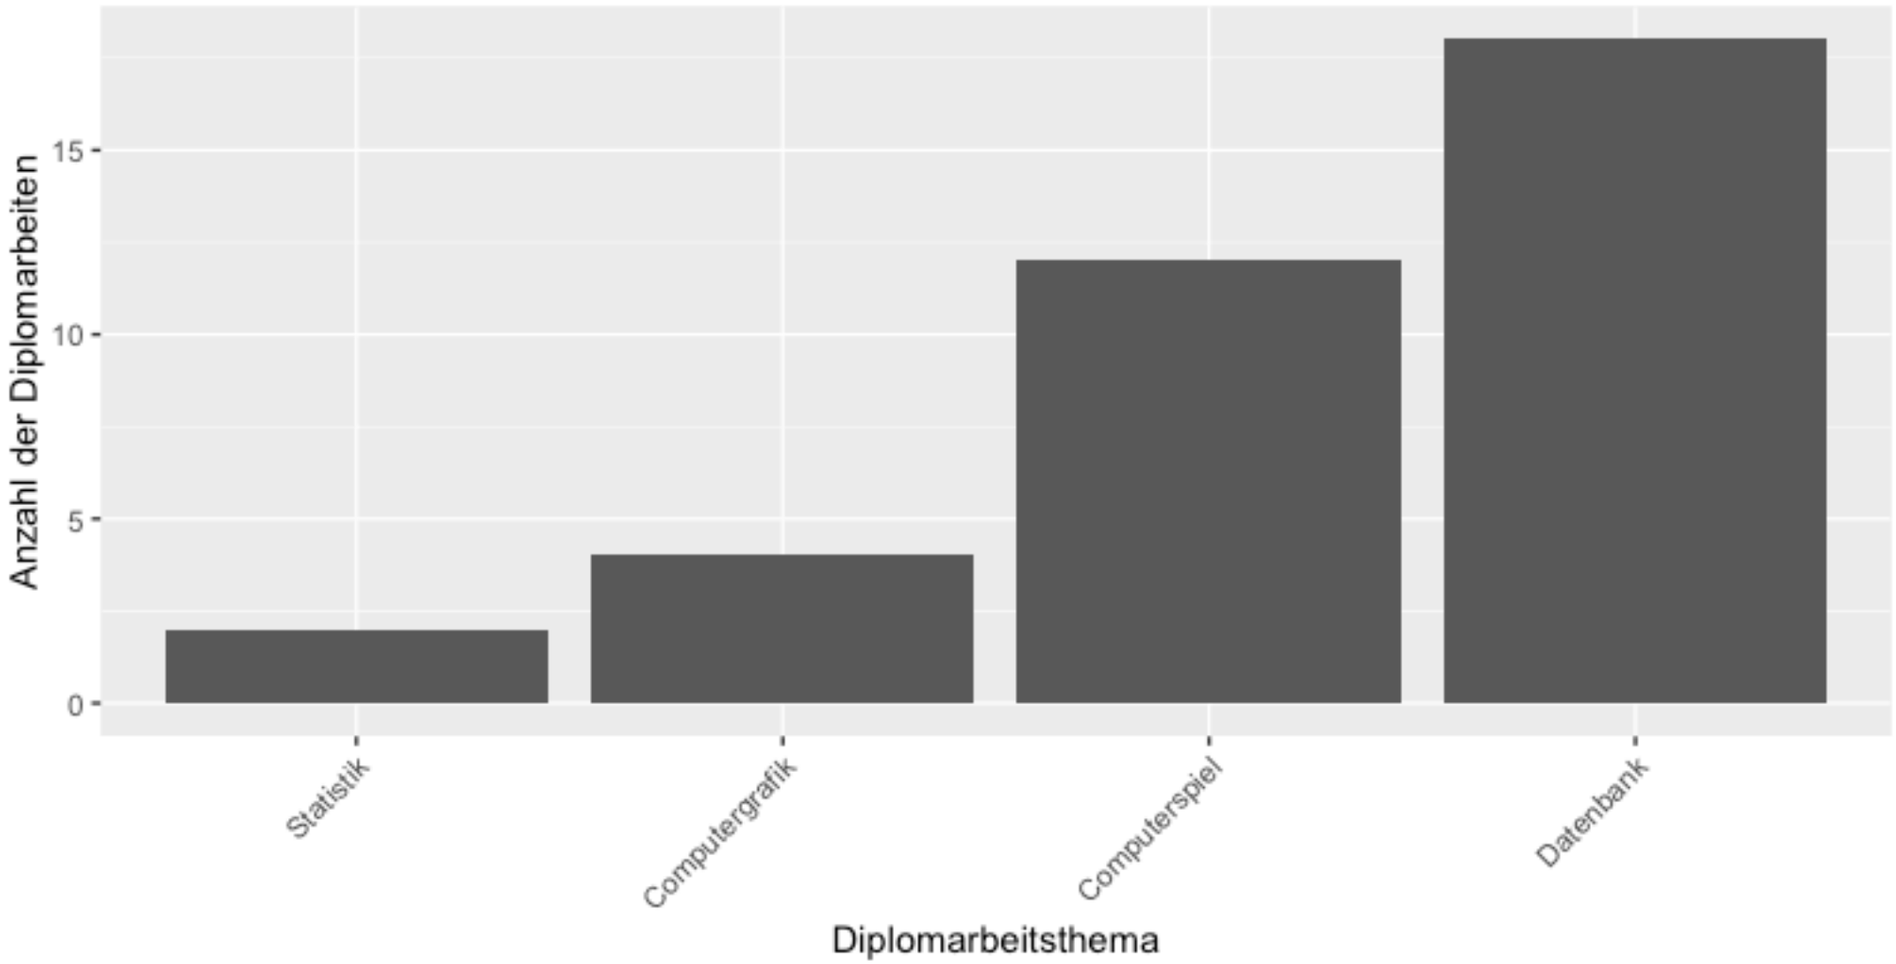
Vertikale Balkendiagramme*



- Ausprägungen a_j auf der x-Achse
- Häufigkeiten h_j auf der y-Achse

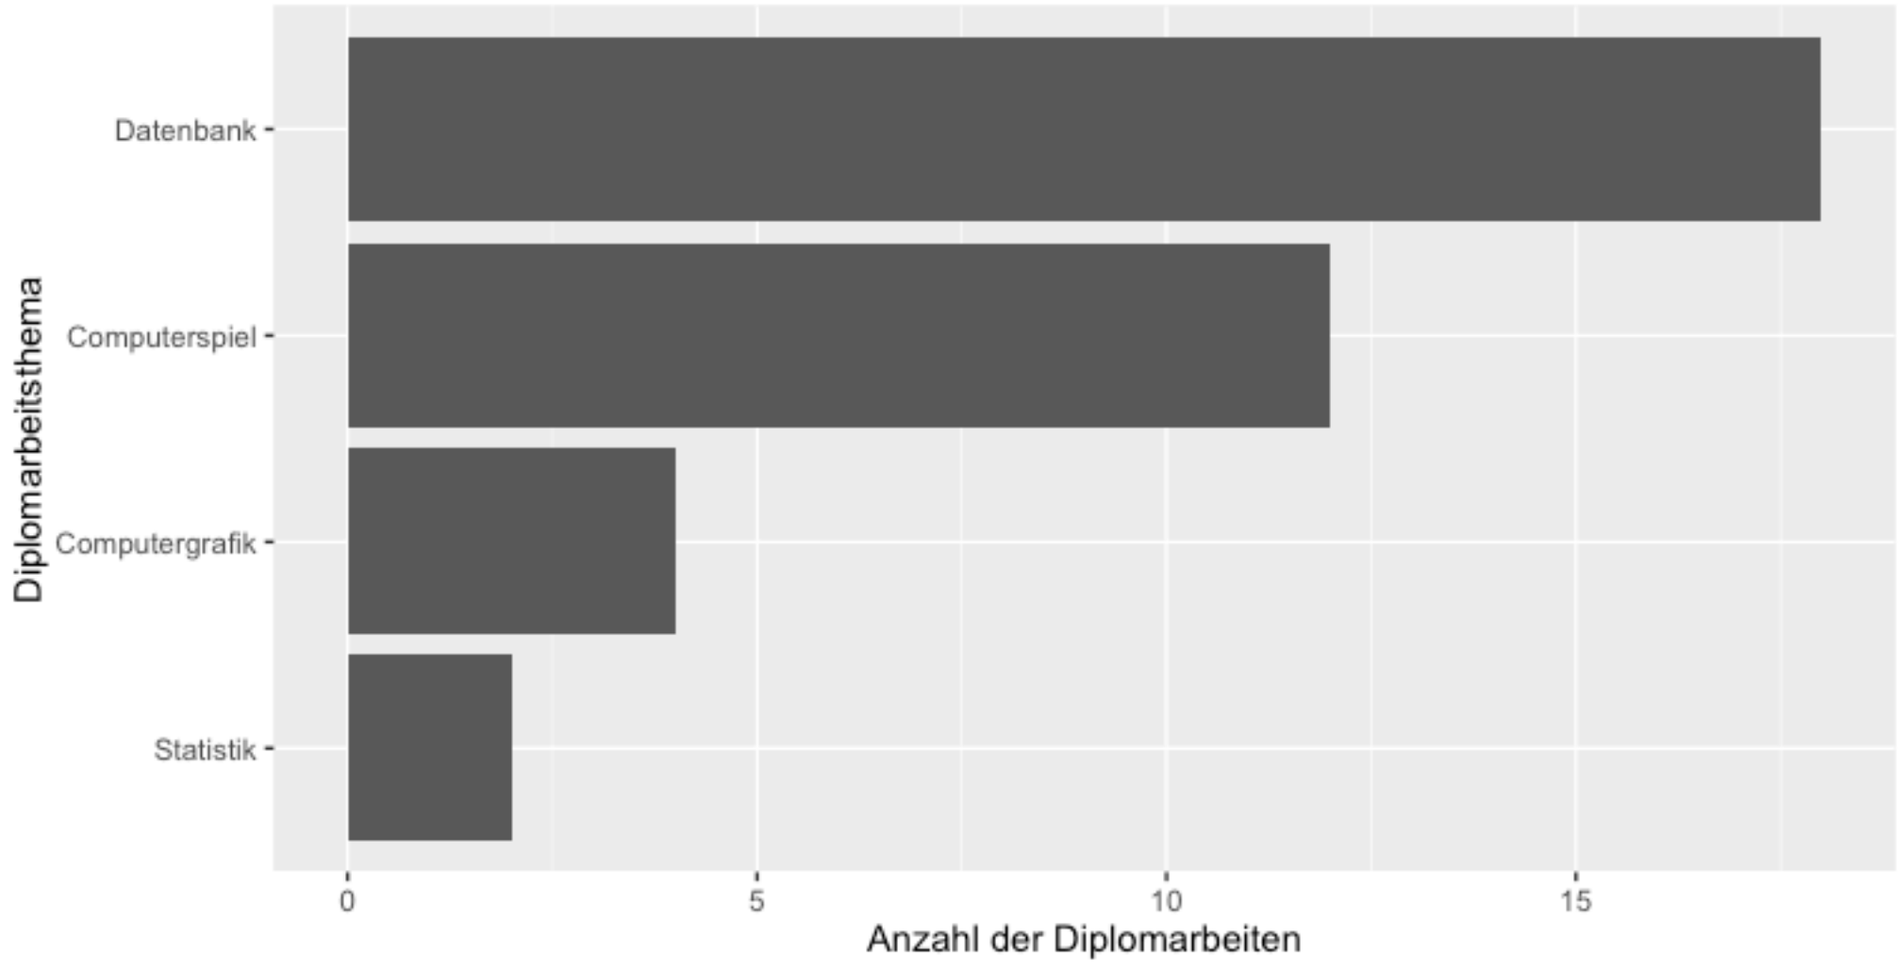
*englisch: *bar charts*

Vertikale Balkendiagramme



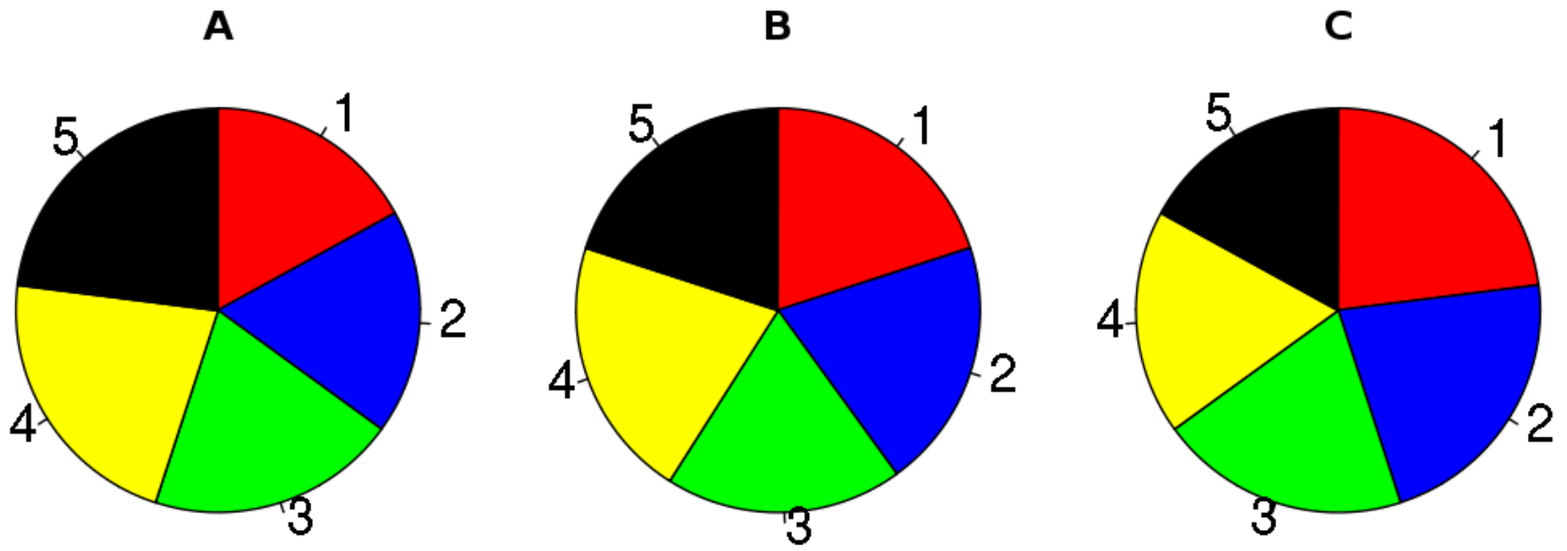
- Vertikale oder schräge Labels bei langen Wörtern

Horizontale Balkendiagramme



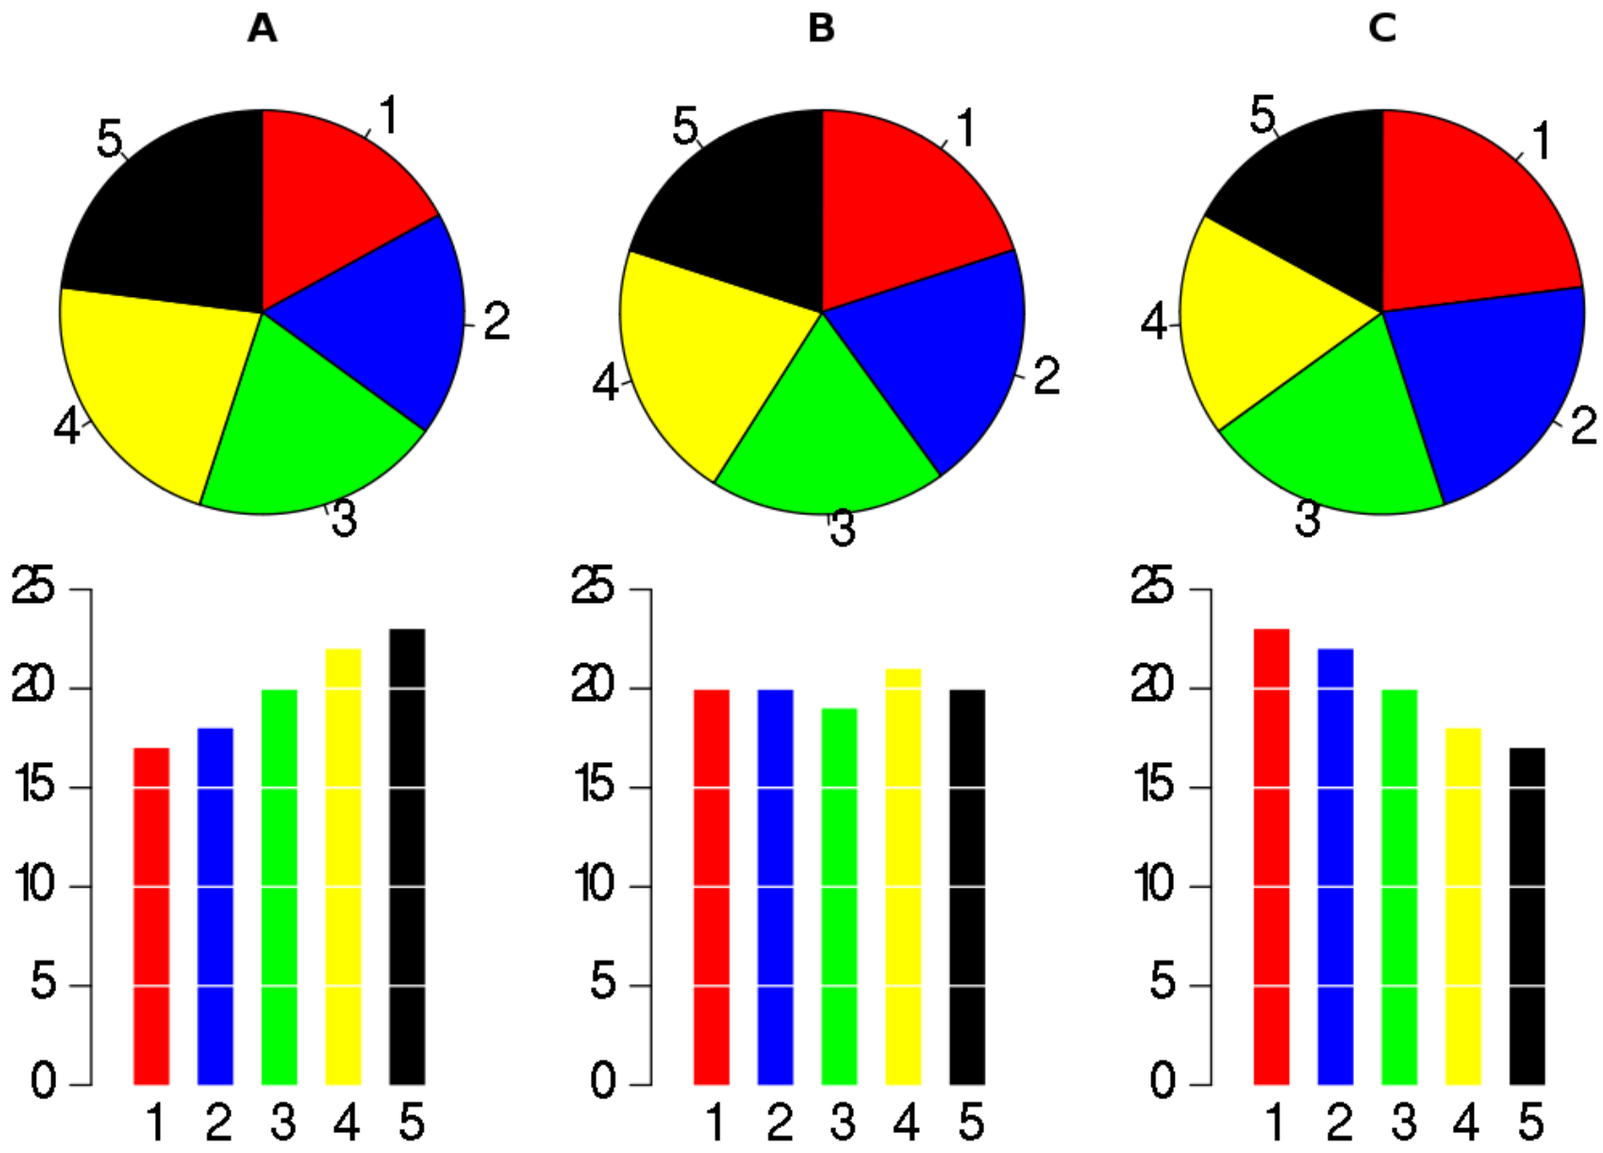
- Ausprägungen a_j auf der y-Achse
- Häufigkeiten h_j auf der x-Achse
- auch gut geeignet bei langen Labeltexten

Kreisdiagramme* sind zu vermeiden ...



*englisch: *pie charts*

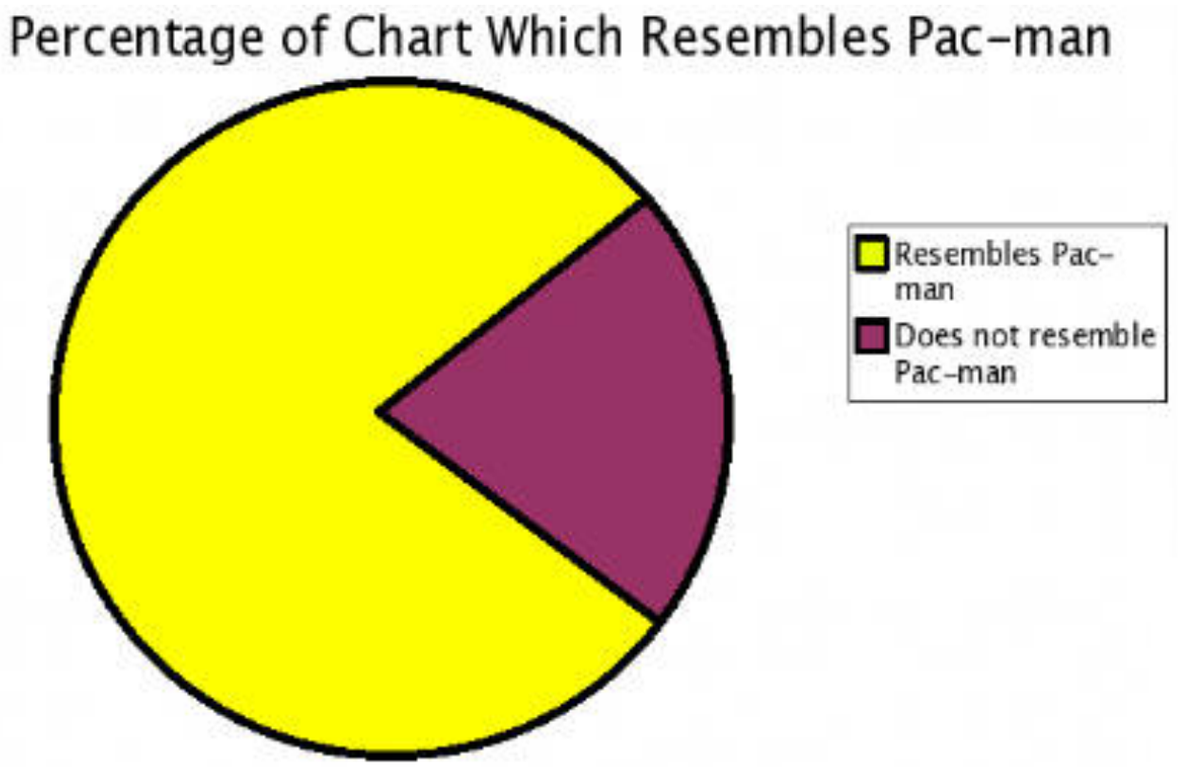
Kreisdiagramme* sind zu vermeiden ...

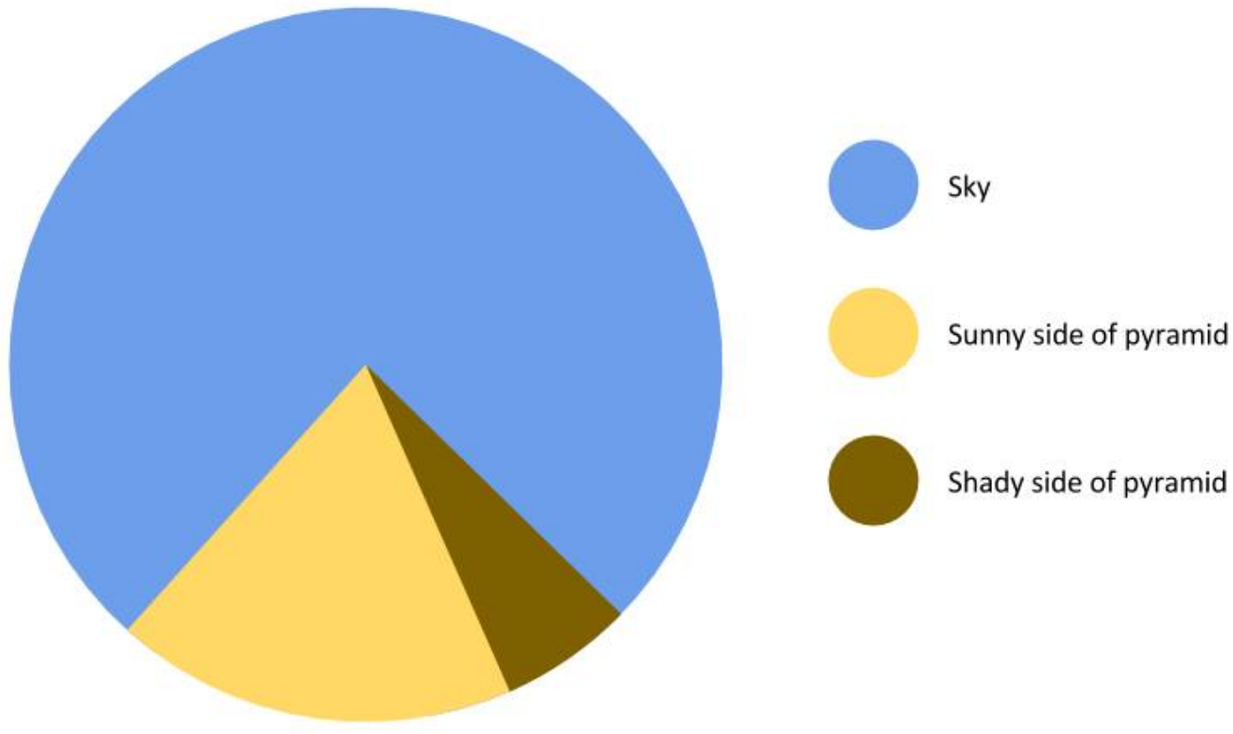


Unterschiedliche Werte sind in Balkendiagrammen viel besser zu erkennen

*englisch: *pie charts*

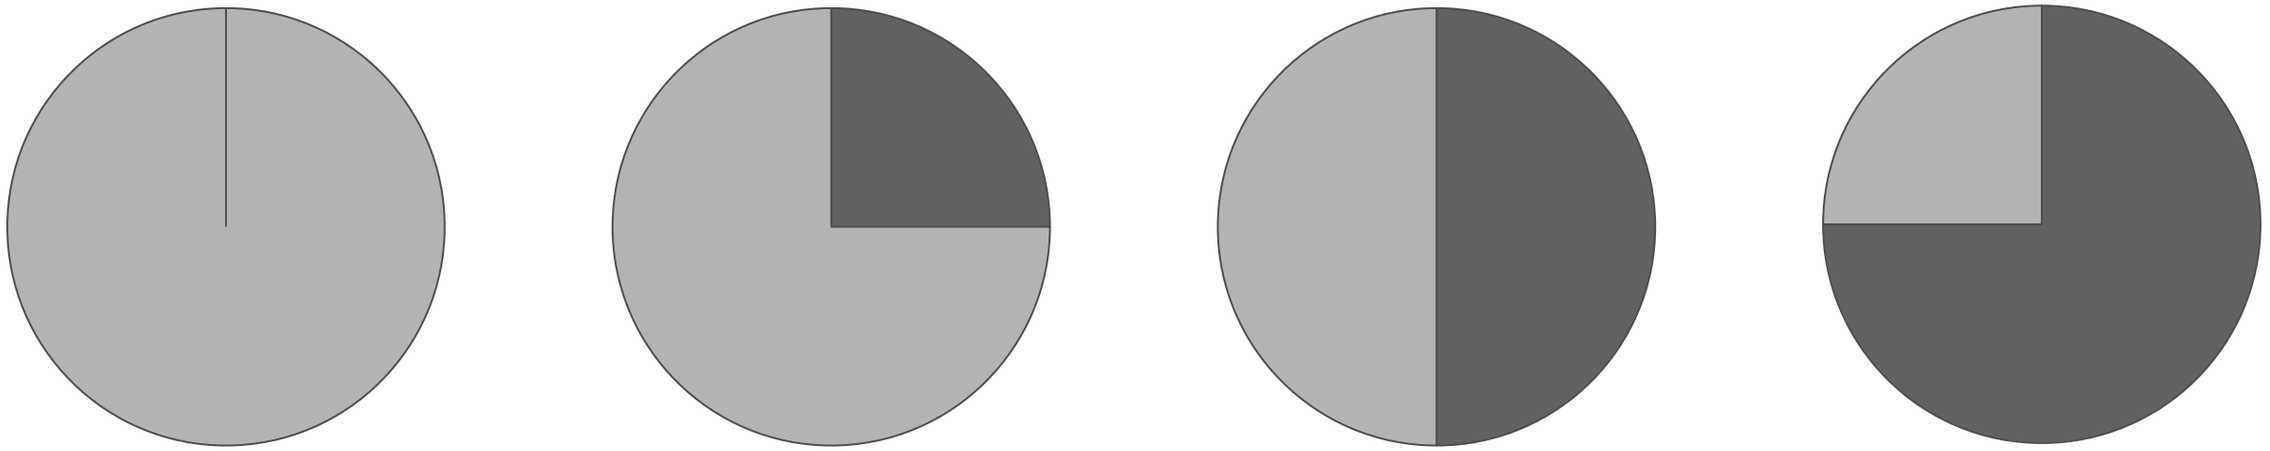
… es sei denn, man macht sich darüber lustig!





Ausnahme

¼, ½, ¾ und 1 können visuell gut in Kreisdiagrammen dargestellt werden



Viele verschiedene Werte

Häufigkeitstabellen und Balkendiagramme sind nützlich, wenn die Daten $x_1, x_2, \ldots x_n$ eher wenige verschiedene Werte $a_1, a_2, \ldots a_k$ annehmen, d.h. $k << n$.

Was können wir tun, wenn k in der gleichen Größenordnung ist wie n oder sogar $k = n$, d.h. wenn jedes Datum hat einen anderen Wert hat?

Beispiel: Über ein Jahr messen wir jeden Tag die Temperatur an derselben Stelle um dieselbe Uhrzeit

Gruppieren von Werten I

Beispiel Nettomieten von $n = 26$ Wohnungen [1]

Da alle Werte verschieden sind, ist k = n und $\{x_1, x_2, \ldots x_n\} = \{a_1, a_2, \ldots a_k\}$.

Die absoluten Häufigkeiten h_j sind alle 1 und die relativen f_j sind alle $h_j / n = 1 / 26$.

77.31	104.14	132.24	158.91	163.17	166.40	170.04
181.98	183.09	200.84	210.55	227.91	243.44	255.75
261.98	263.21	269.84	276.60	281.21	311.87	343.30
359.17	361.60	362.00	400.05	533.92		

Gruppieren von Werten II

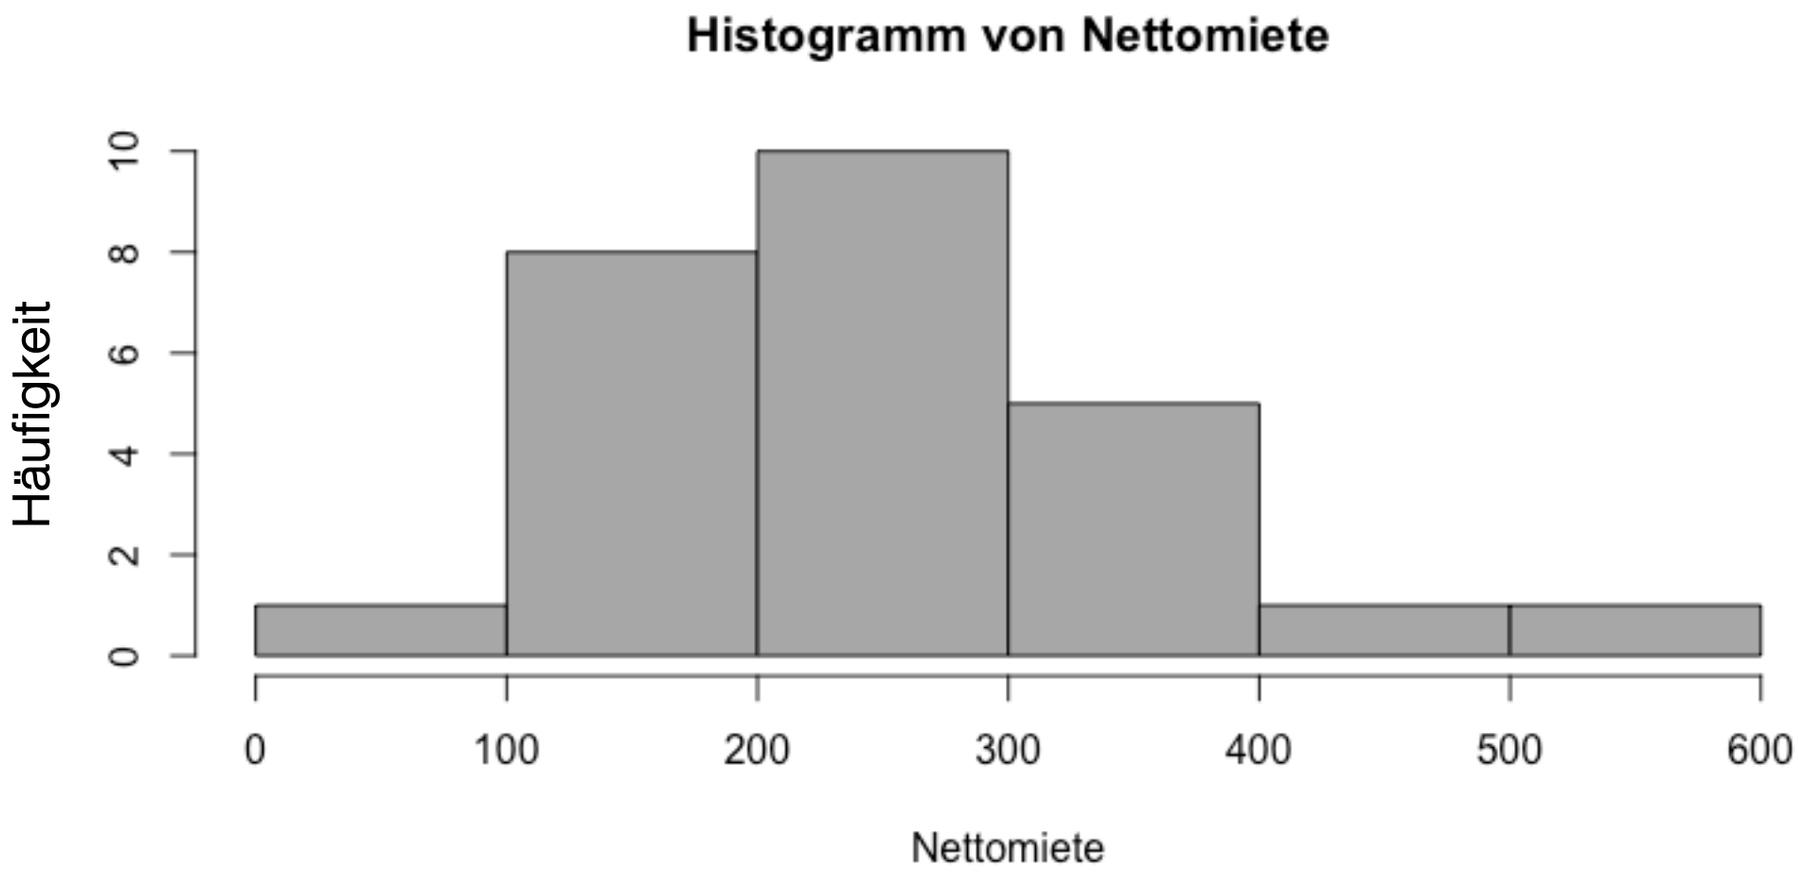
Wenn die Anzahl der Ausprägungen groß ist, dann wird eine Analyse komplizierter. Man kann dann Werte ***gruppieren (klassieren)*** und mit einer kleineren Häufigkeitstabelle arbeiten.

Klasse	absolute Häufigkeit	relative Häufigkeit
$0 < \ldots \leq 100$	1	$1/26 = 0.038$
$100 < \ldots \leq 200$	8	$8/26 = 0.308$
$200 < \ldots \leq 300$	10	$10/26 = 0.385$
$300 < \ldots \leq 400$	5	$5/26 = 0.192$
$400 < \ldots \leq 500$	1	$1/26 = 0.038$
$500 < \ldots \leq 600$	1	$1/26 = 0.038$

Warum Gruppieren?

- Analyse einfacher
- wenn eine natürliche Gruppierung existiert, z.B. Zensuren
- Aggregation zum Datenschutz
- Manchmal Datenerhebungen schon gruppiert, um Antwortverweigerungen oder –verzerrungen zu minimieren, z.B. Frage nach dem Alter

Histogramme I



Gruppiere (klassiere) quantitative Merkmale und zeichne Häufigkeiten über Klassenintervallen

Klasse	absolute Häufigkeit	relative Häufigkeit
$0 < \ldots \leq 100$	1	$1/26 = 0.038$
$100 < \ldots \leq 200$	8	$8/26 = 0.308$
$200 < \ldots \leq 300$	10	$10/26 = 0.385$
$300 < \ldots \leq 400$	5	$5/26 = 0.192$
$400 < \ldots \leq 500$	1	$1/26 = 0.038$
$500 < \ldots \leq 600$	1	$1/26 = 0.038$

Histogramme II

Zeichne über den Klassen $[c_0, c_1), \ldots, [c_{k-1}, c_k)$ Rechtecke mit

Breite:	$d_j = c_j - c_{j-1}$
Höhe:	gleich (oder proportional zu) h_j/d_j bzw. f_j/d_j
Fläche:	gleich (oder proportional zu) h_j bzw. f_j

- Da unsere Augen primär die Fläche der Rechtecke und nicht die Höhe wahrnehmen, werden Histogramme so konstruiert, dass die **Fläche der Rechtecke** proportional zur Häufigkeit ist, **nicht die Höhe der Rechtecke**
- Die durch die Klassenbreite modifizierte Höhe (wie oben definiert) nennt man ***Häufigkeitsdichte***
- Wenn alle Klassen gleich breit sind, ist aber auch die Höhe proportional zur Häufigkeit

Histogramme III

Wie wählt man die Klassen?

- Anzahl, Ort, Breite?

Faustregeln (aber sie sind zum Brechen da)

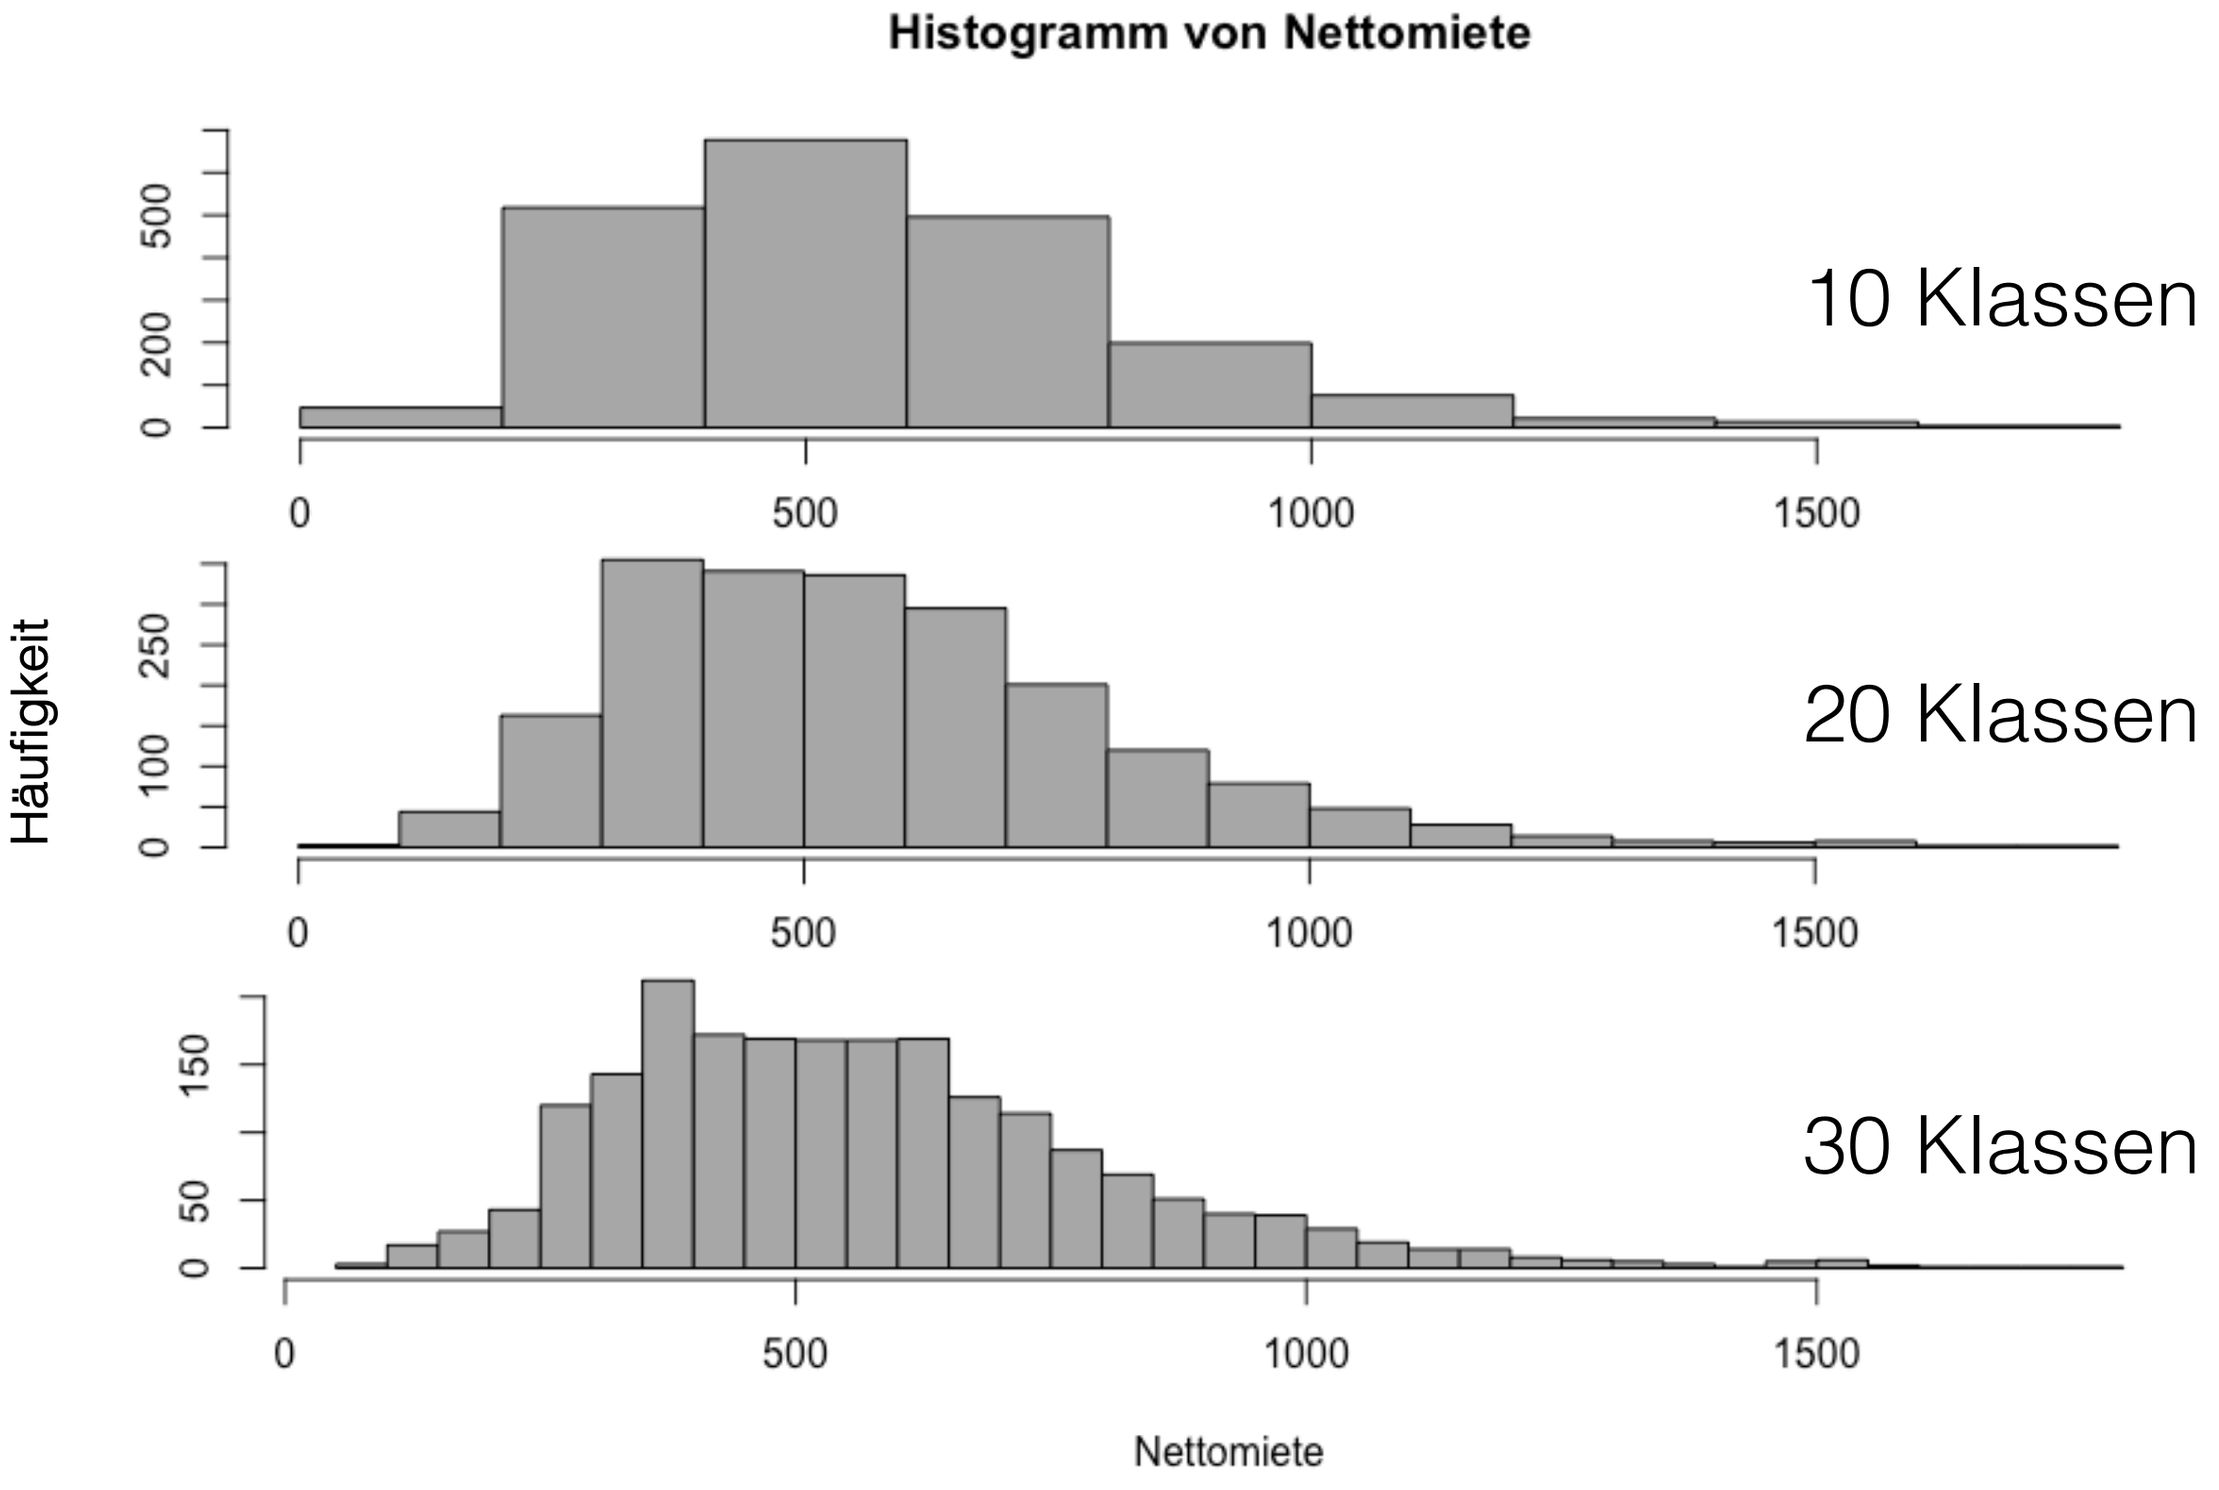
- Klassen sollten gleich breit sein
- Klassengrenzen meist sinnvoll gerundet auf 10, 100 etc.
- Anwendung diktiert oft Klassenbreite (wie fein sollen wir auflösen?)
- alternativ Anordnung um einen spezifischen Punkt wie Mittelwert
- bei einer Erhebung vom Umfang n wähle als Anzahl k der Klassen

$$k = \sqrt{n}, \; k = 2\sqrt{n} \text{ oder } k = 10 \log_{10} n$$

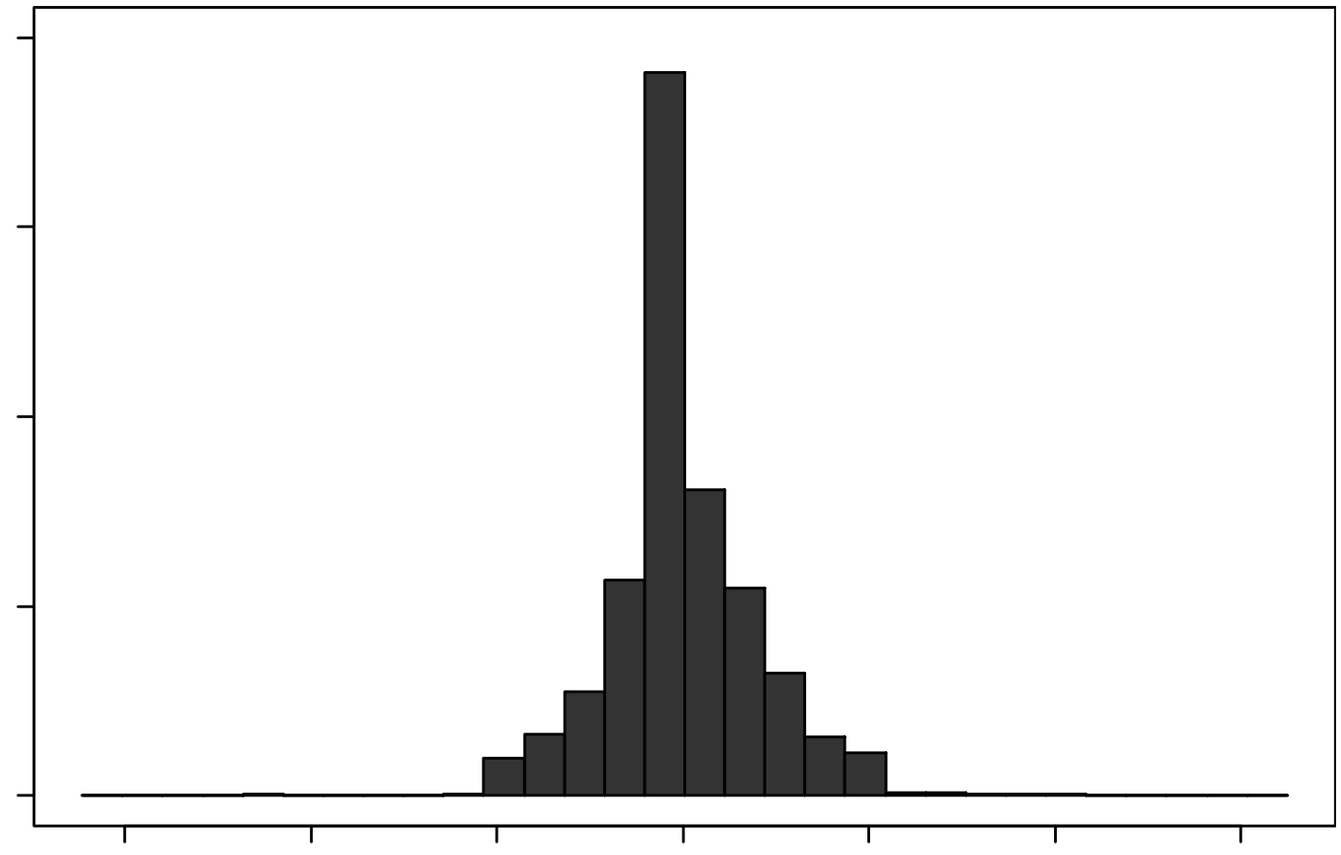
- verschiedene Ansichten sind oft sinnvoll, weil sie verschiedene Eigenschaften zeigen

*englisch: *bins*

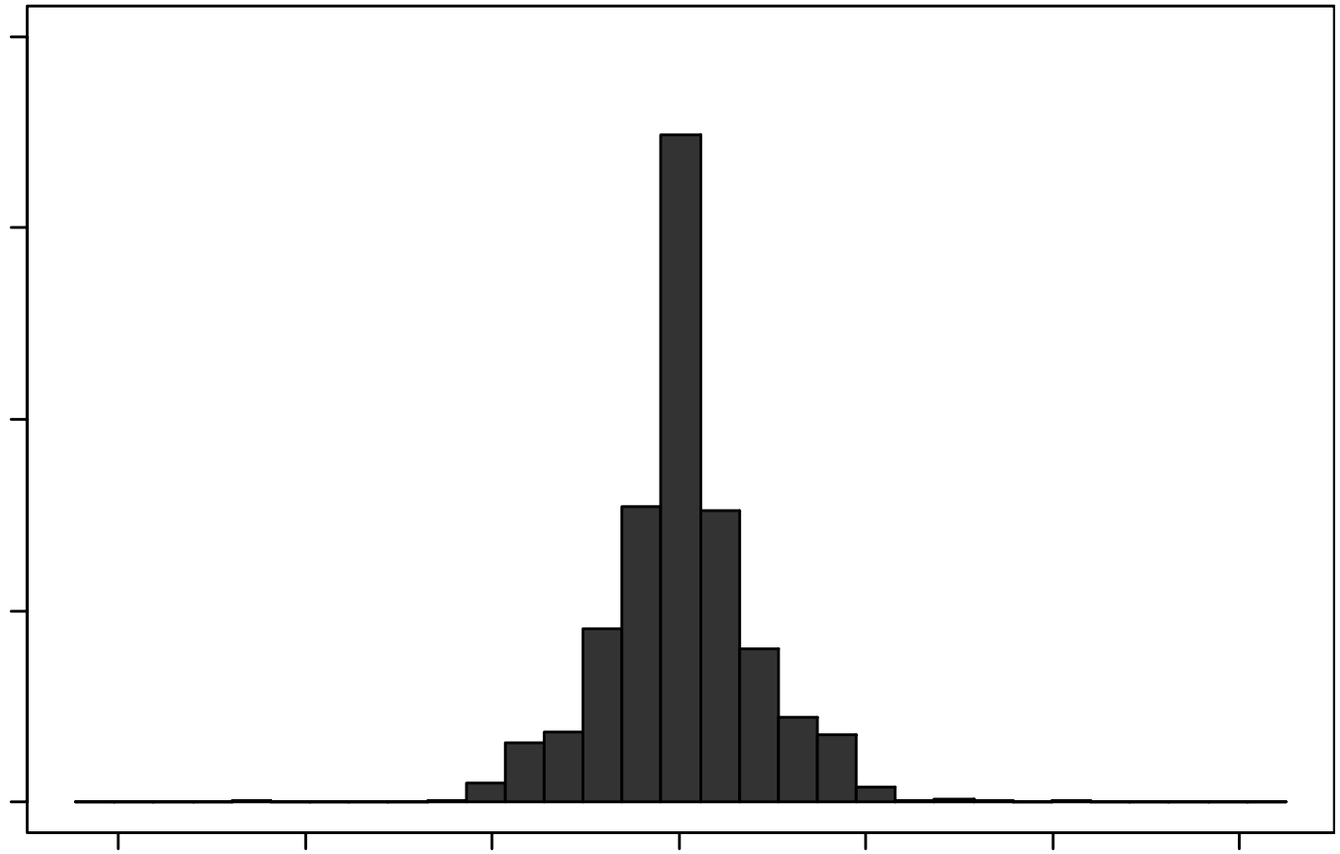
Auflösung beeinflusst visuellen Eindruck



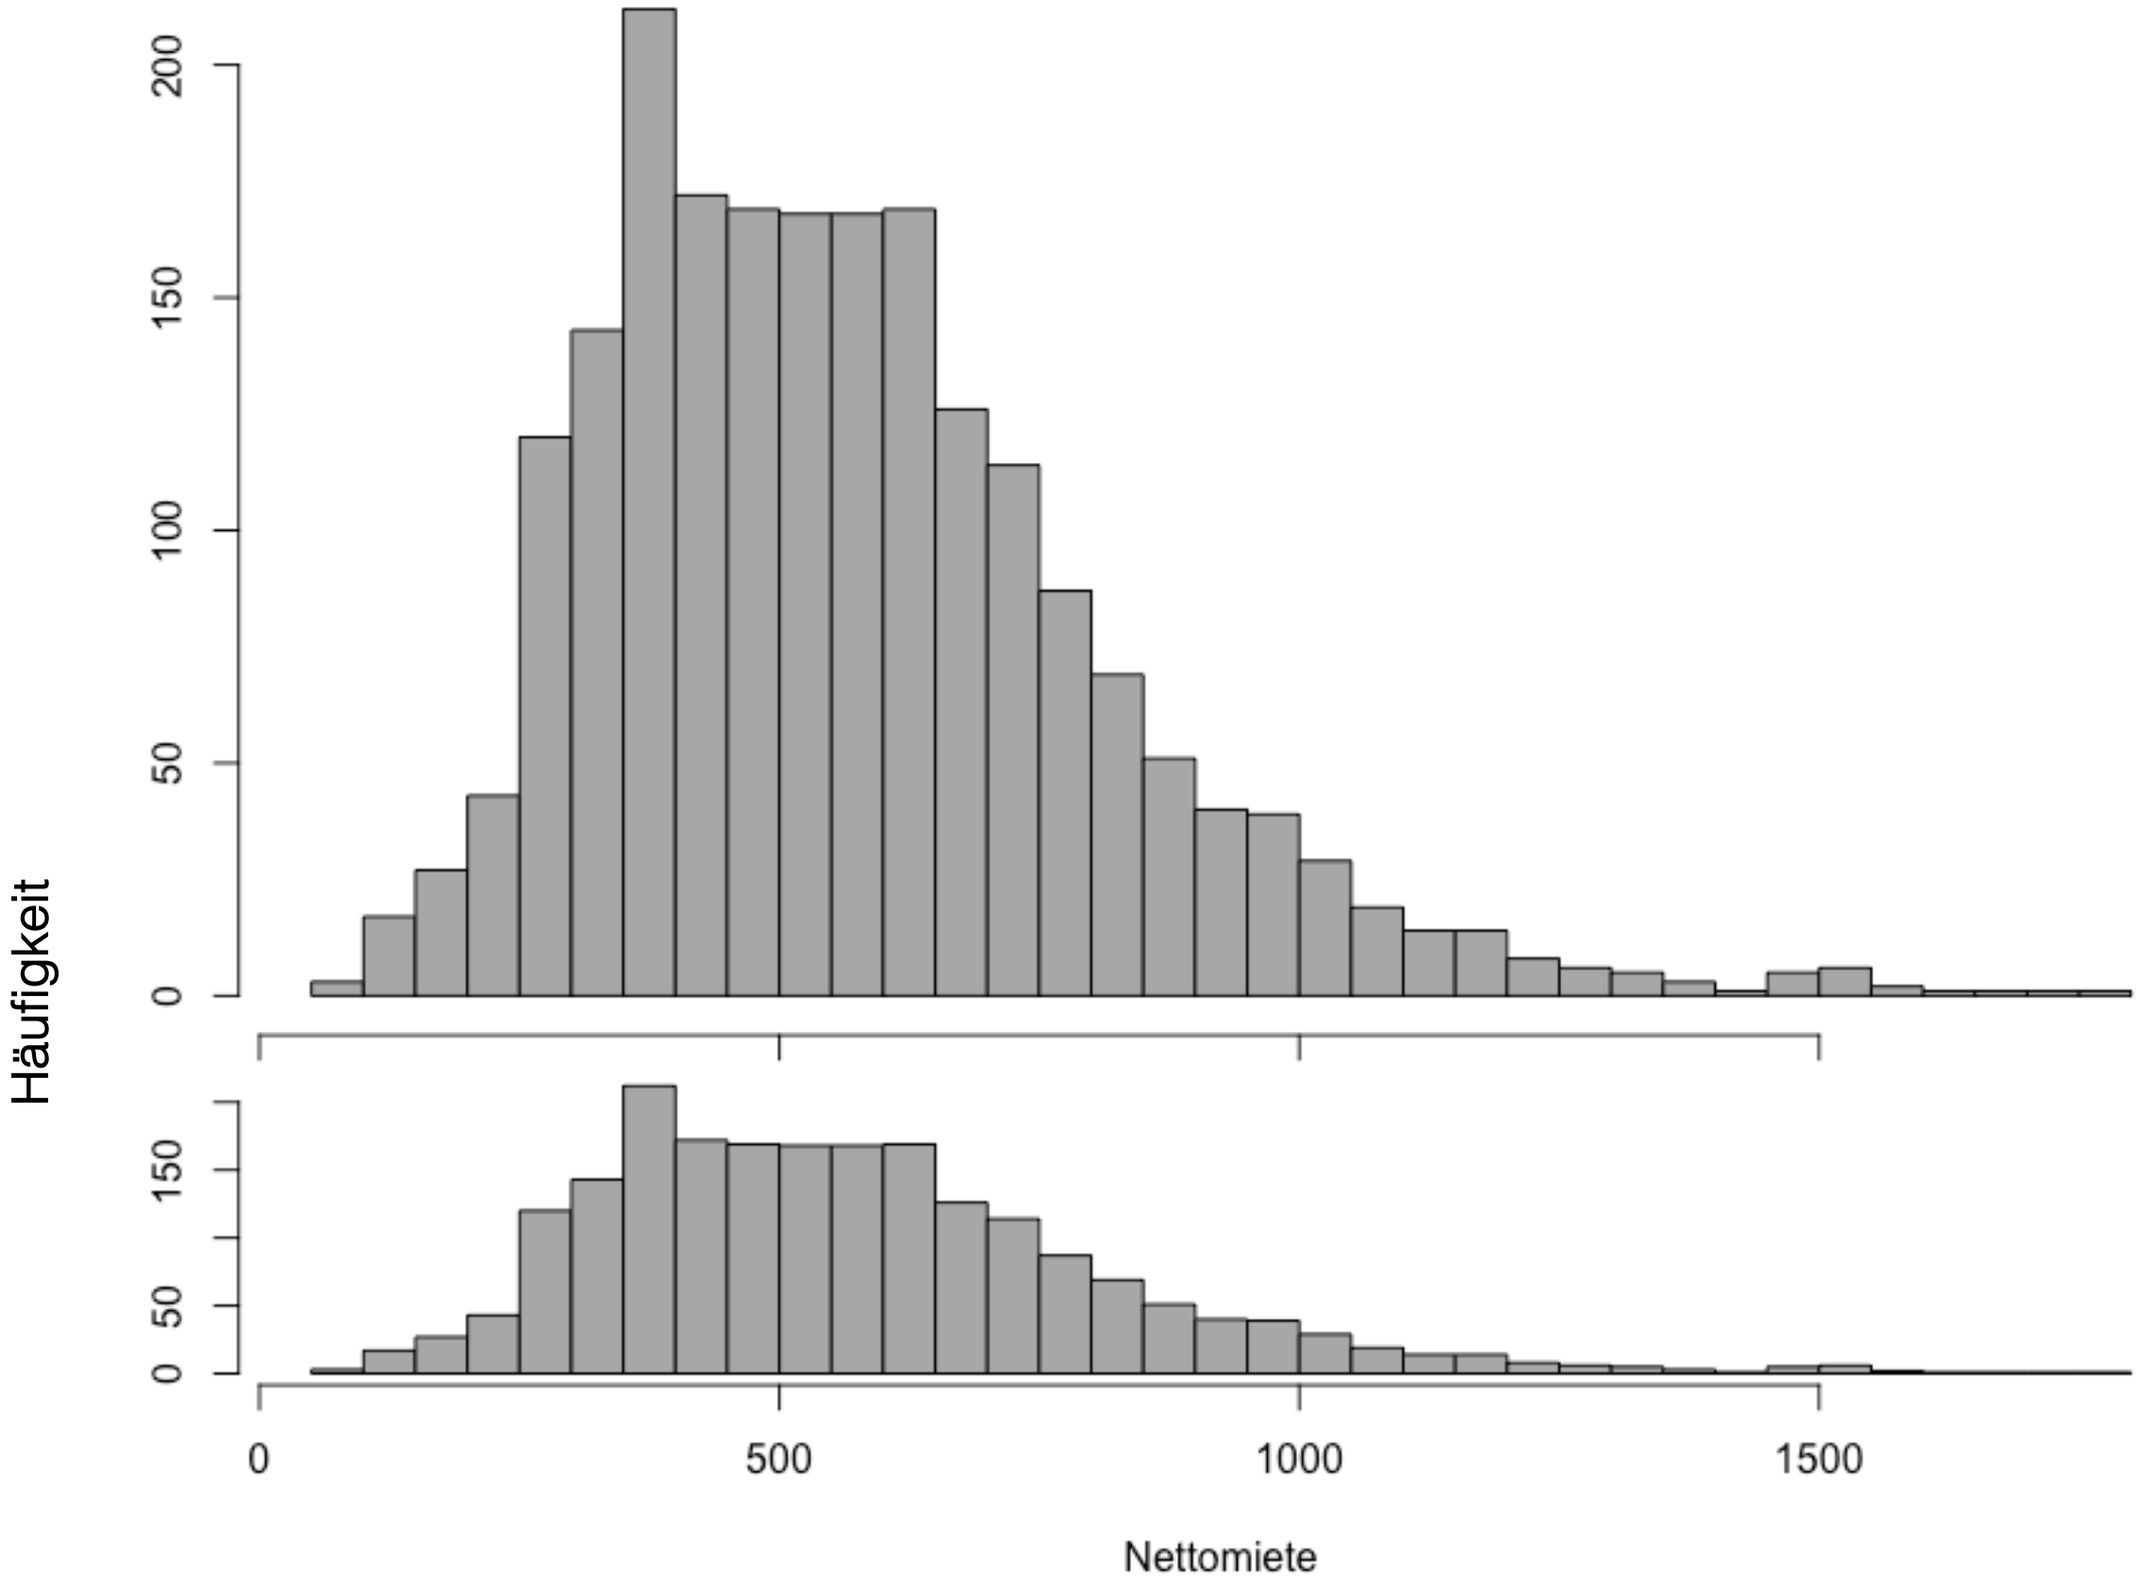
Ort der Klassengrenzen beeinflusst visuellen Eindruck



Tagesrenditen der MRU-Aktie aus [1]

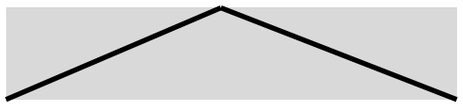


Skalierung beeinflusst visuellen Eindruck



Form des Histogramms

- Modalität





  - ***unimodal*** (eingipfelig), ***bimodal*** (zweigipfelig), ***multimodal*** (mehrgipfelig)

- Symmetrie um den Gipfel
  - ***symmetrisch*** abfallend vom Gipfel



  - ***linkssteil*** = ***rechtsschief***



  - ***rechtssteil*** = ***linksschief***



Interpretation

- bi- und multimodale Histogramme sind unter Umständen die Konsequenz davon, dass verschiedene Gruppen gemischt sind

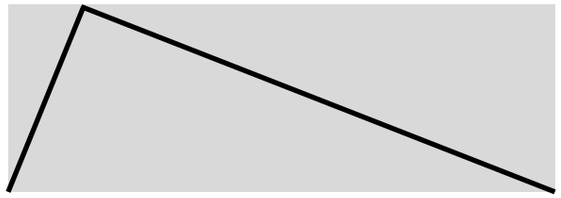
- bei schiefen Verteilungen ist die Spanne verschiedener Werte nicht symmetrisch um den Gipfel verteilt

- Frage: Sind mehr Werte im steileren oder im flacheren Teil?
- Allgemeinere Frage: Wo ist welcher Anteil der Werte?

Abstimmung

Frage: Sind mehr Werte im steileren oder im flacheren Teil bei einer linkssteilen Verteilung?

A: im linken, steileren Teil

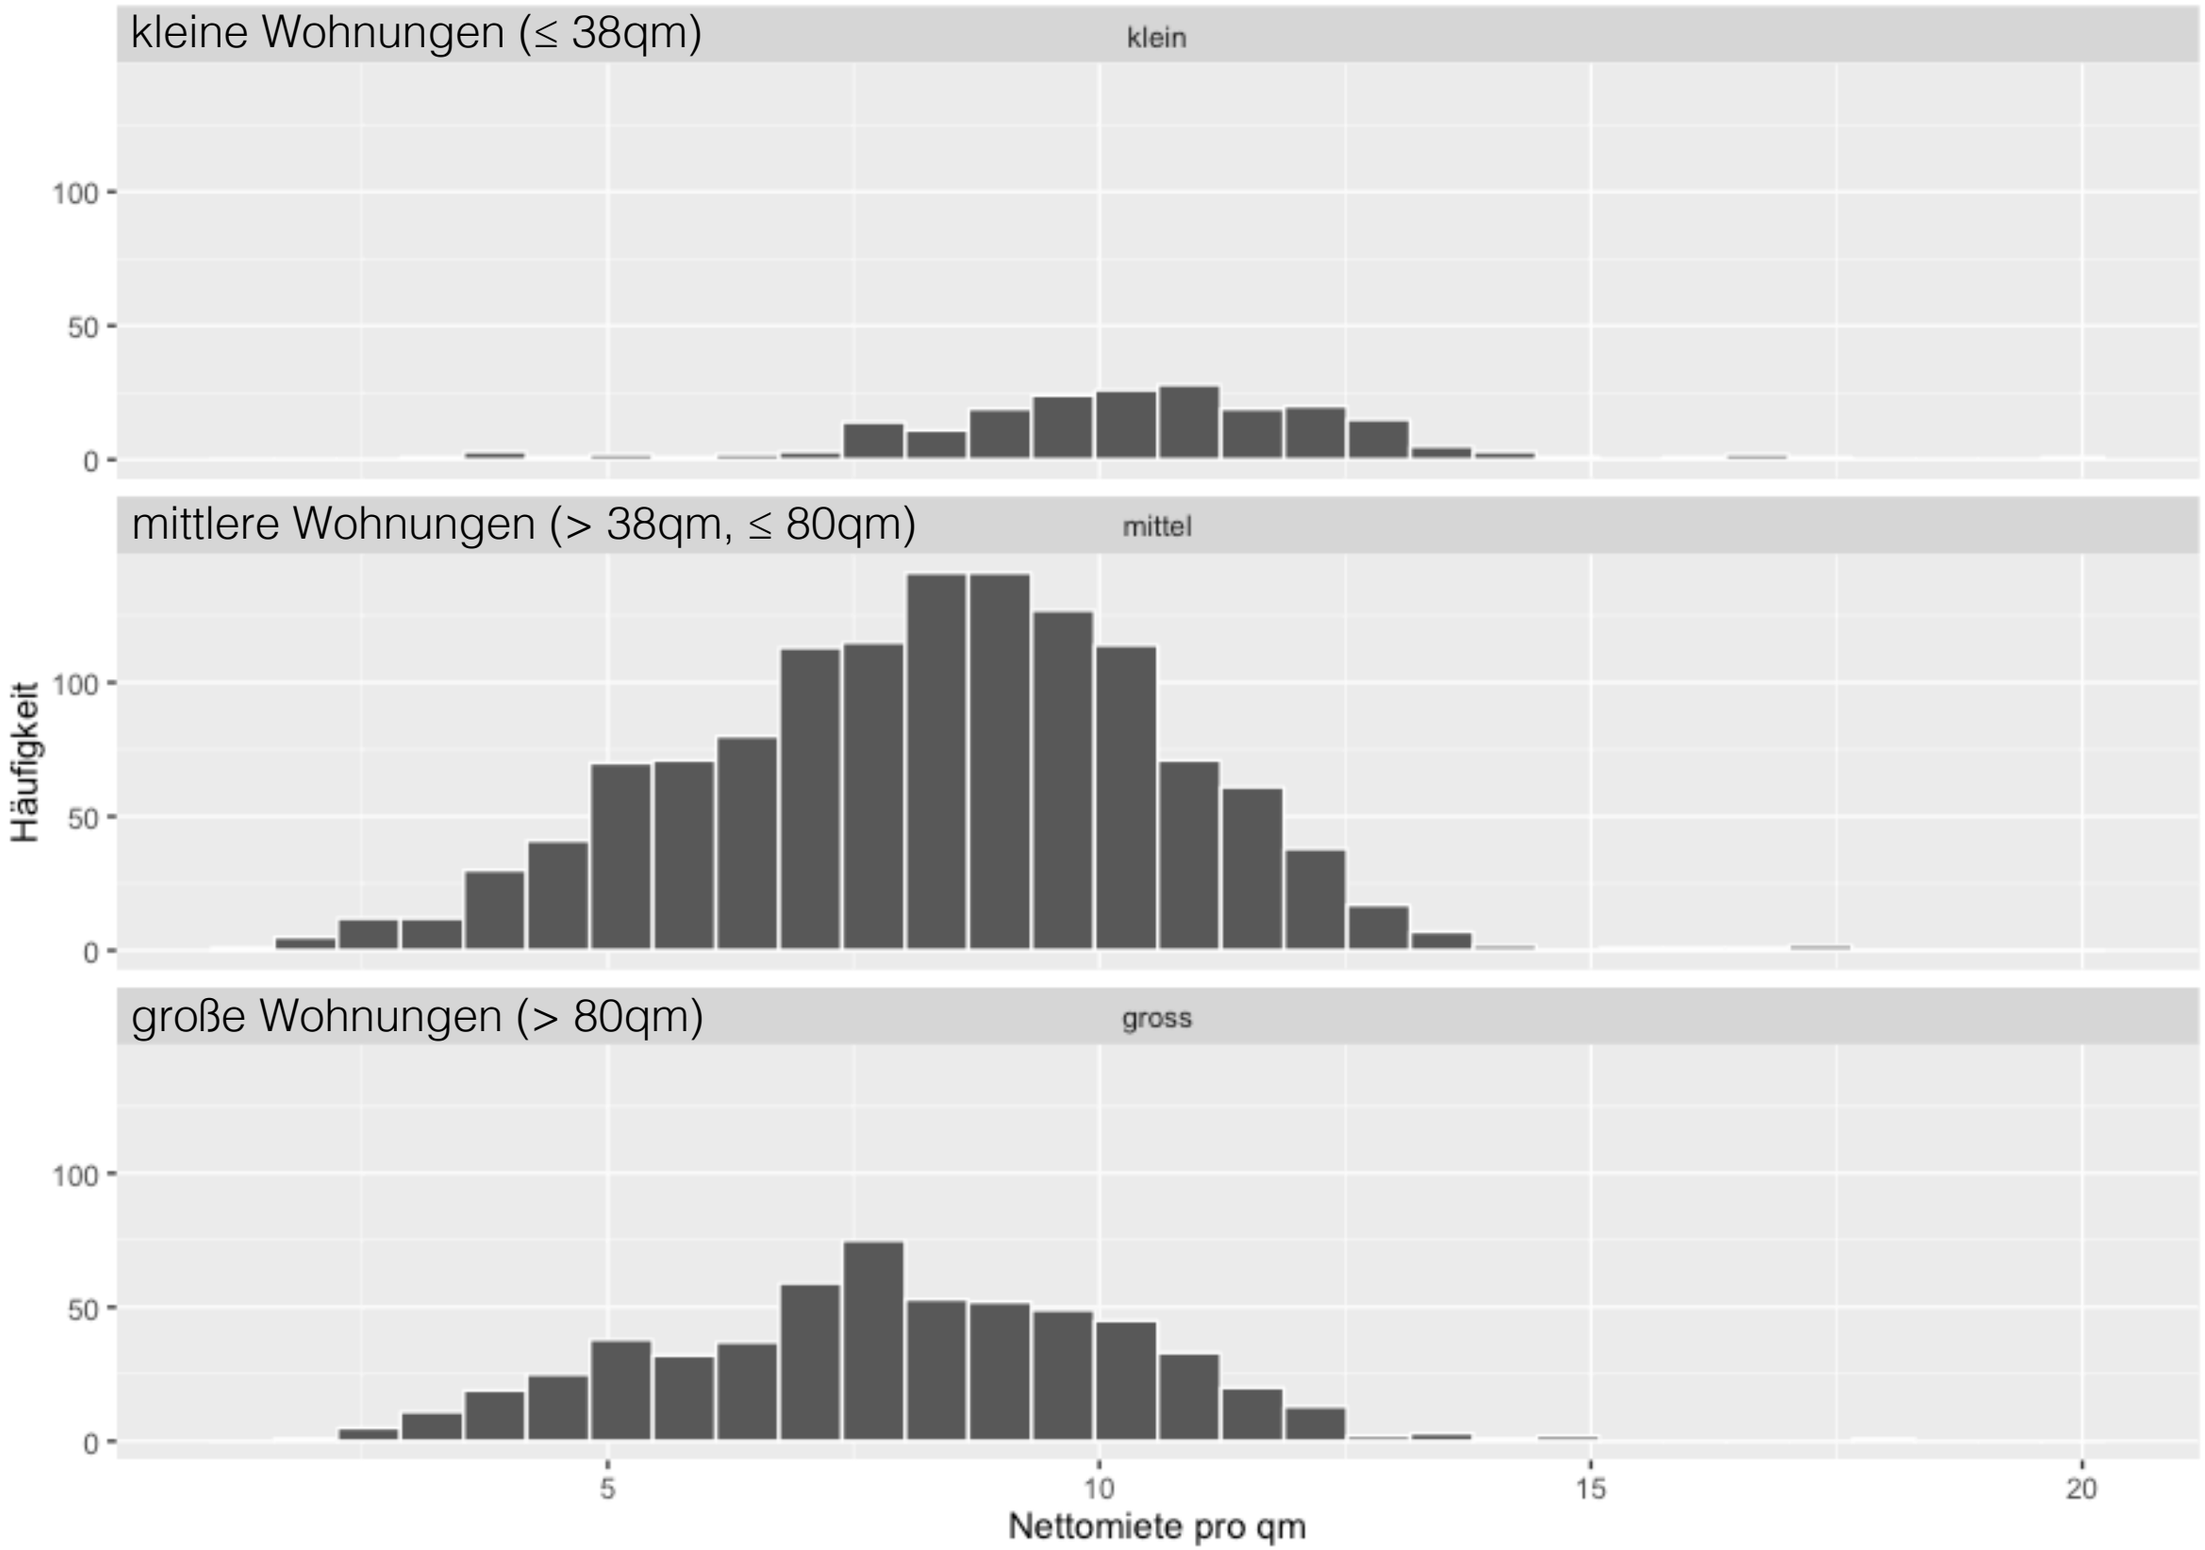


B: im rechten, flacheren Teil

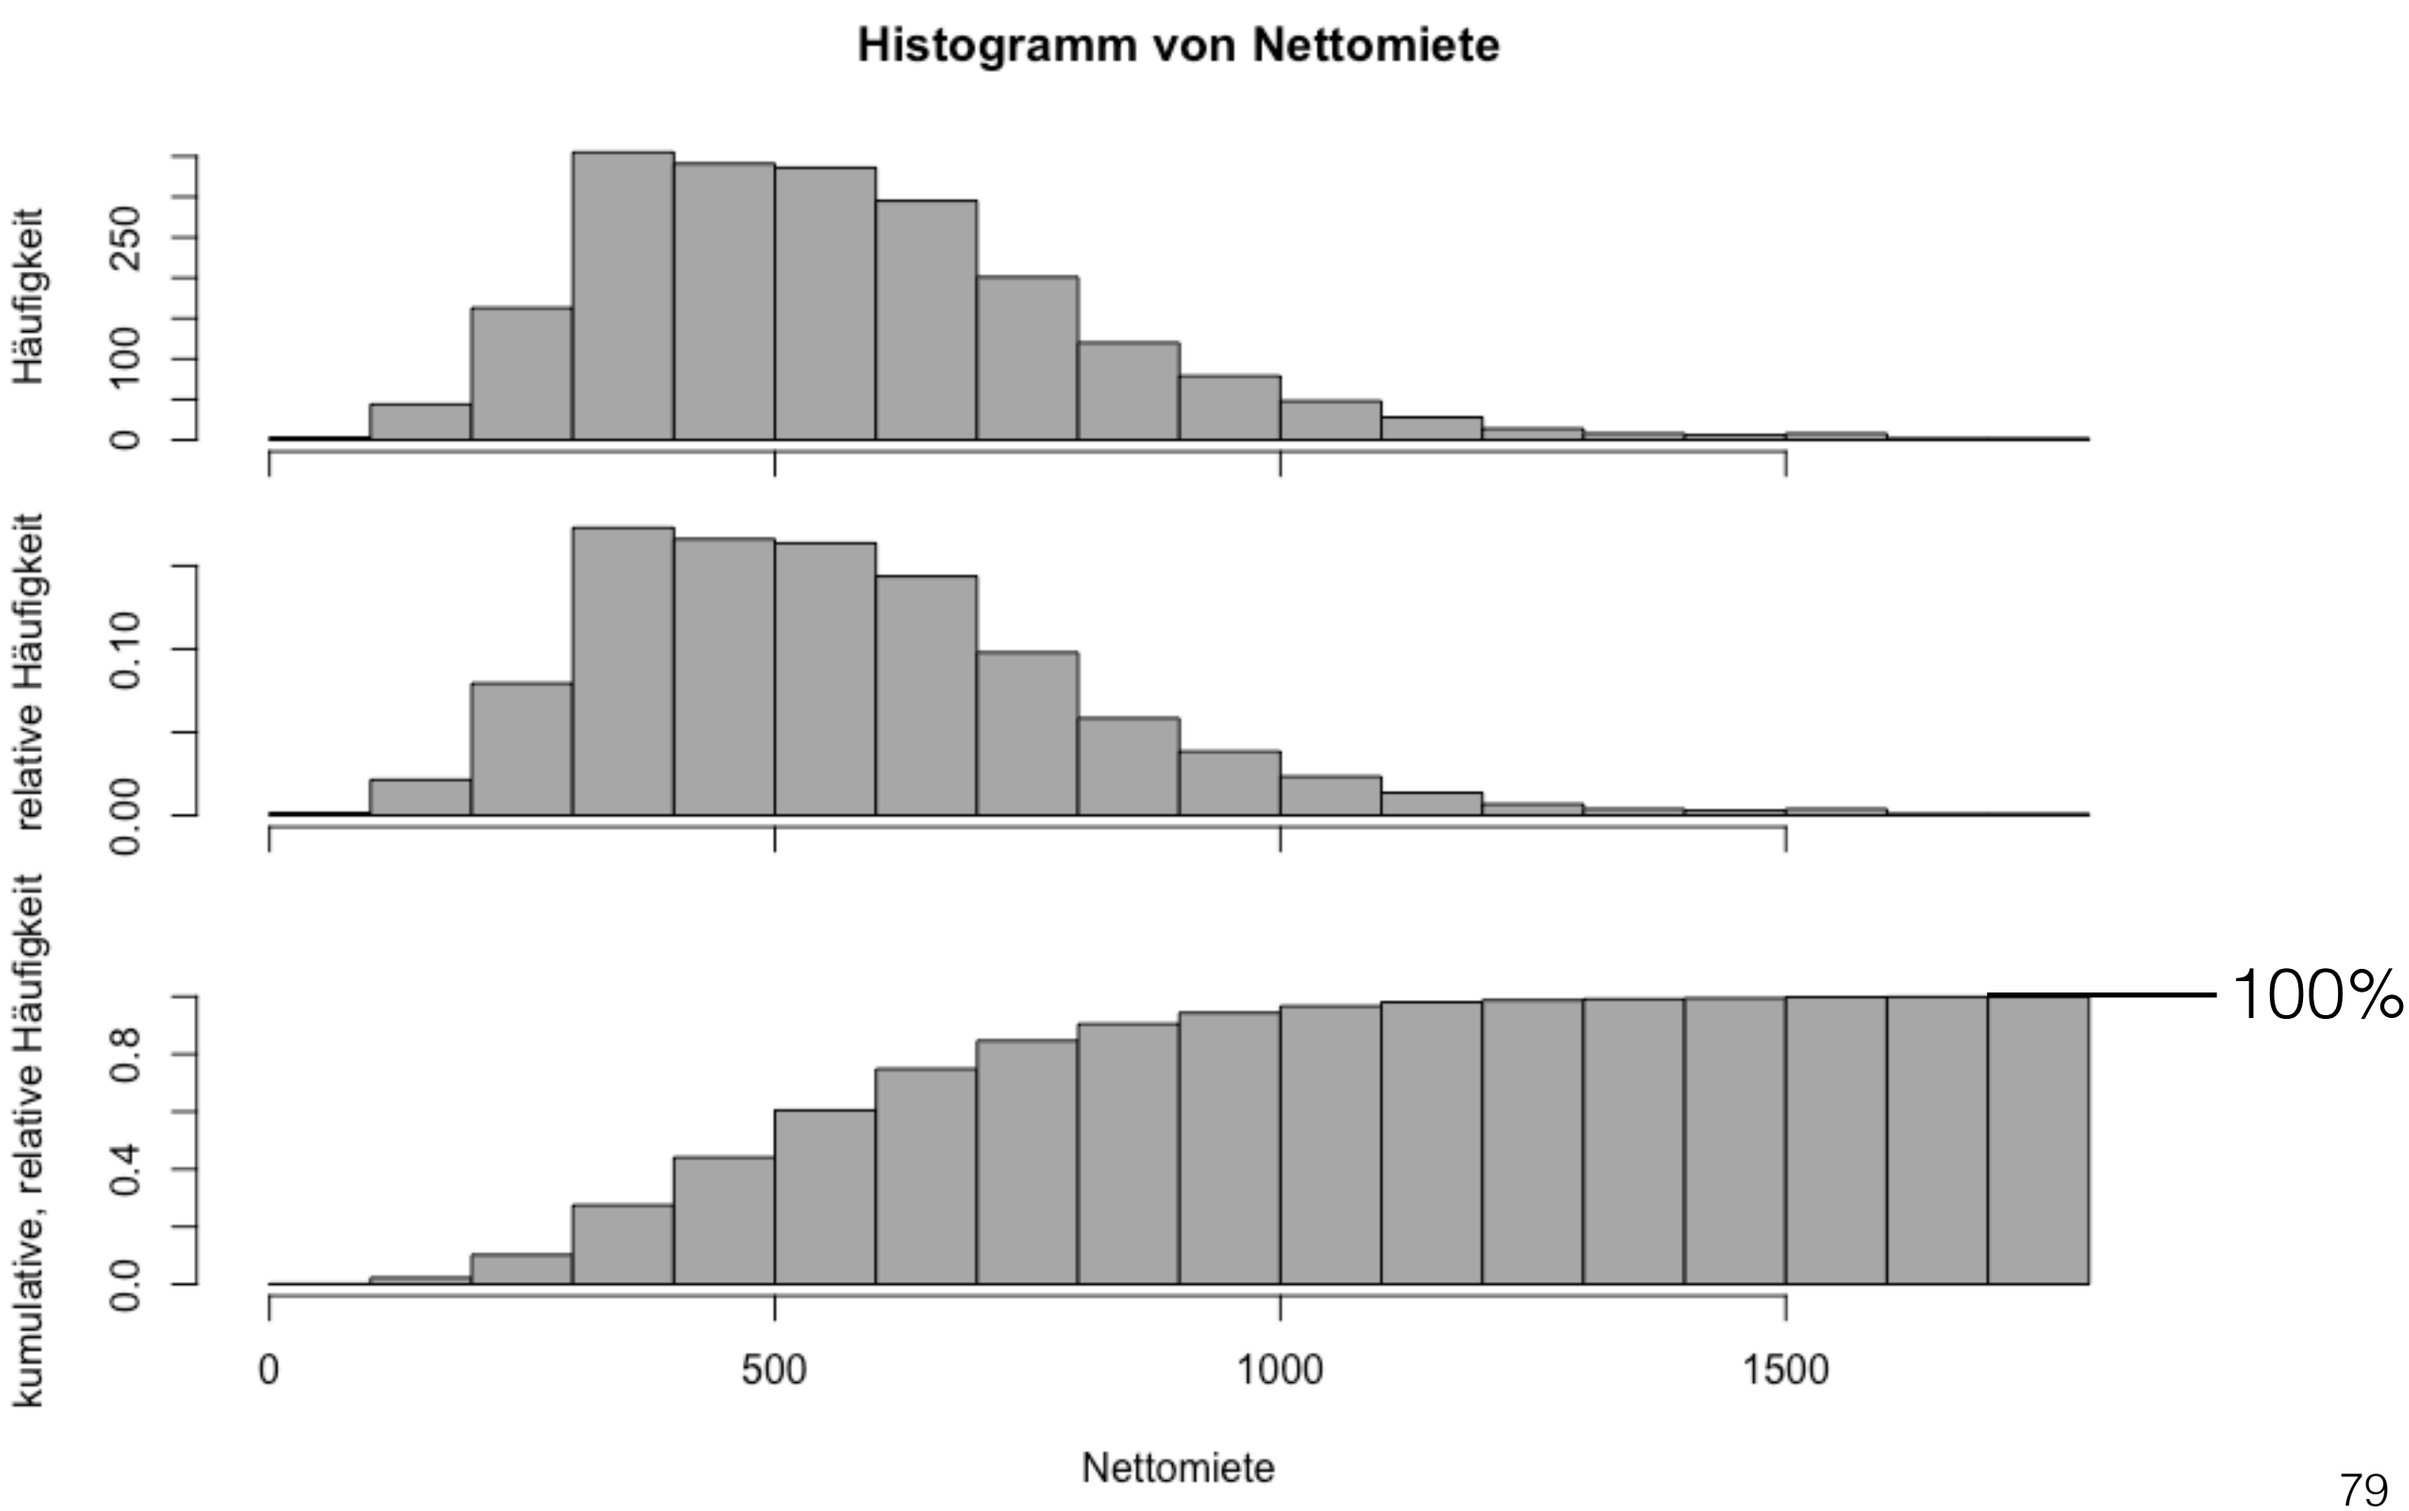
C: weiß nicht

D: ist mir egal

Untersuchung von Teilmengen



[[kumulative] relative] Häufigkeiten



Kumulierte Häufigkeitsverteilung

Welcher Anteil der Daten ist kleiner oder gleich einem interessierenden Wert x?

Absolute kumulierte Häufigkeitsverteilung H(x)

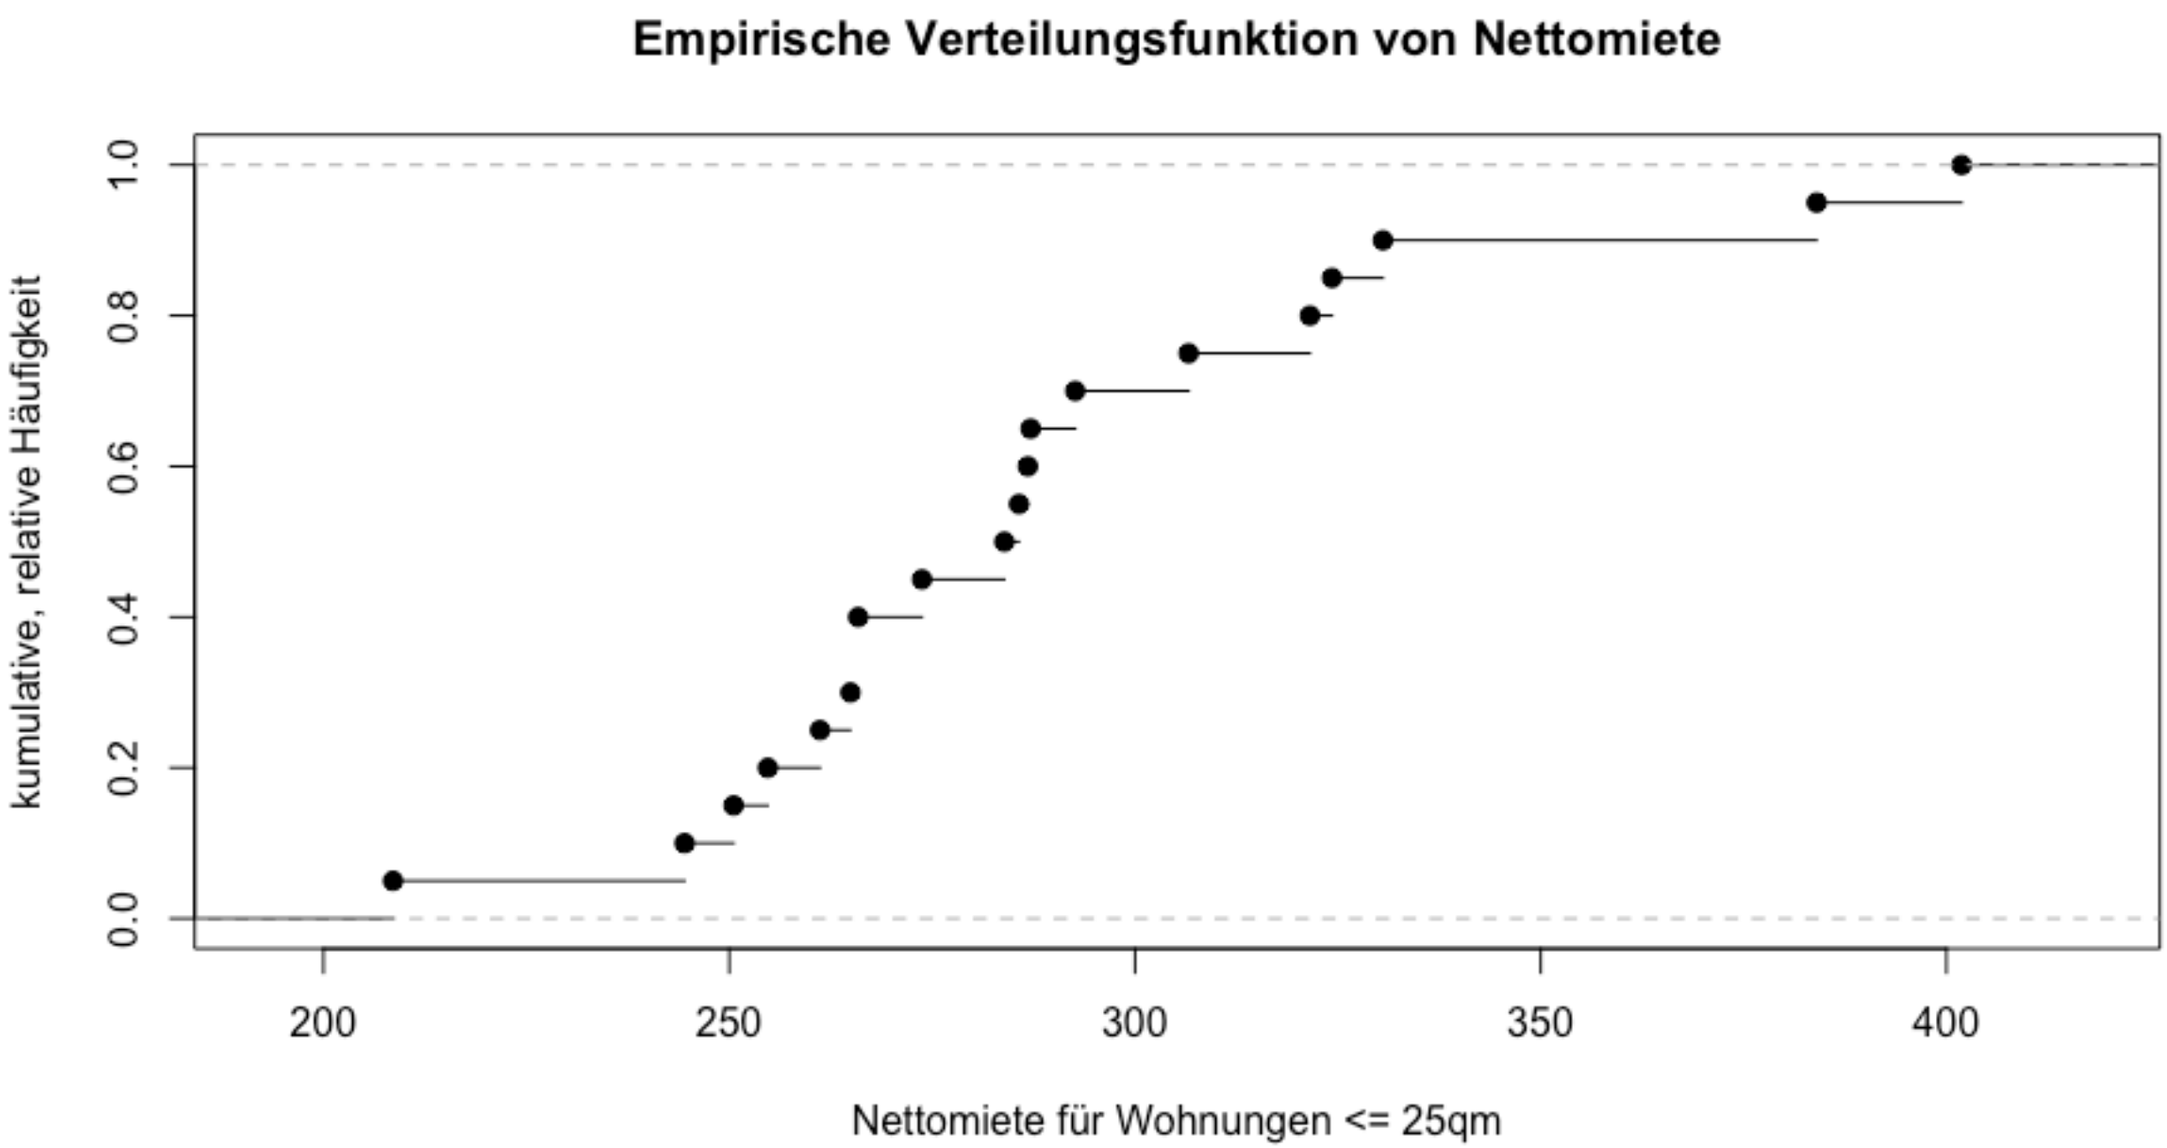
$H(x)$ = Anzahl der Werte x_i mit $x_i \leq x$ mit reeller Zahl x

Relative kumulierte Häufigkeitsverteilung oder Empirische Verteilungsfunktion F(x)

$F(x) = H(x) / n$ = Anteil der Werte x_i mit $x_i \leq x$
mit reeller Zahl x

Beispiel

Nettomiete für die 20 Wohnungen ≤ 25qm

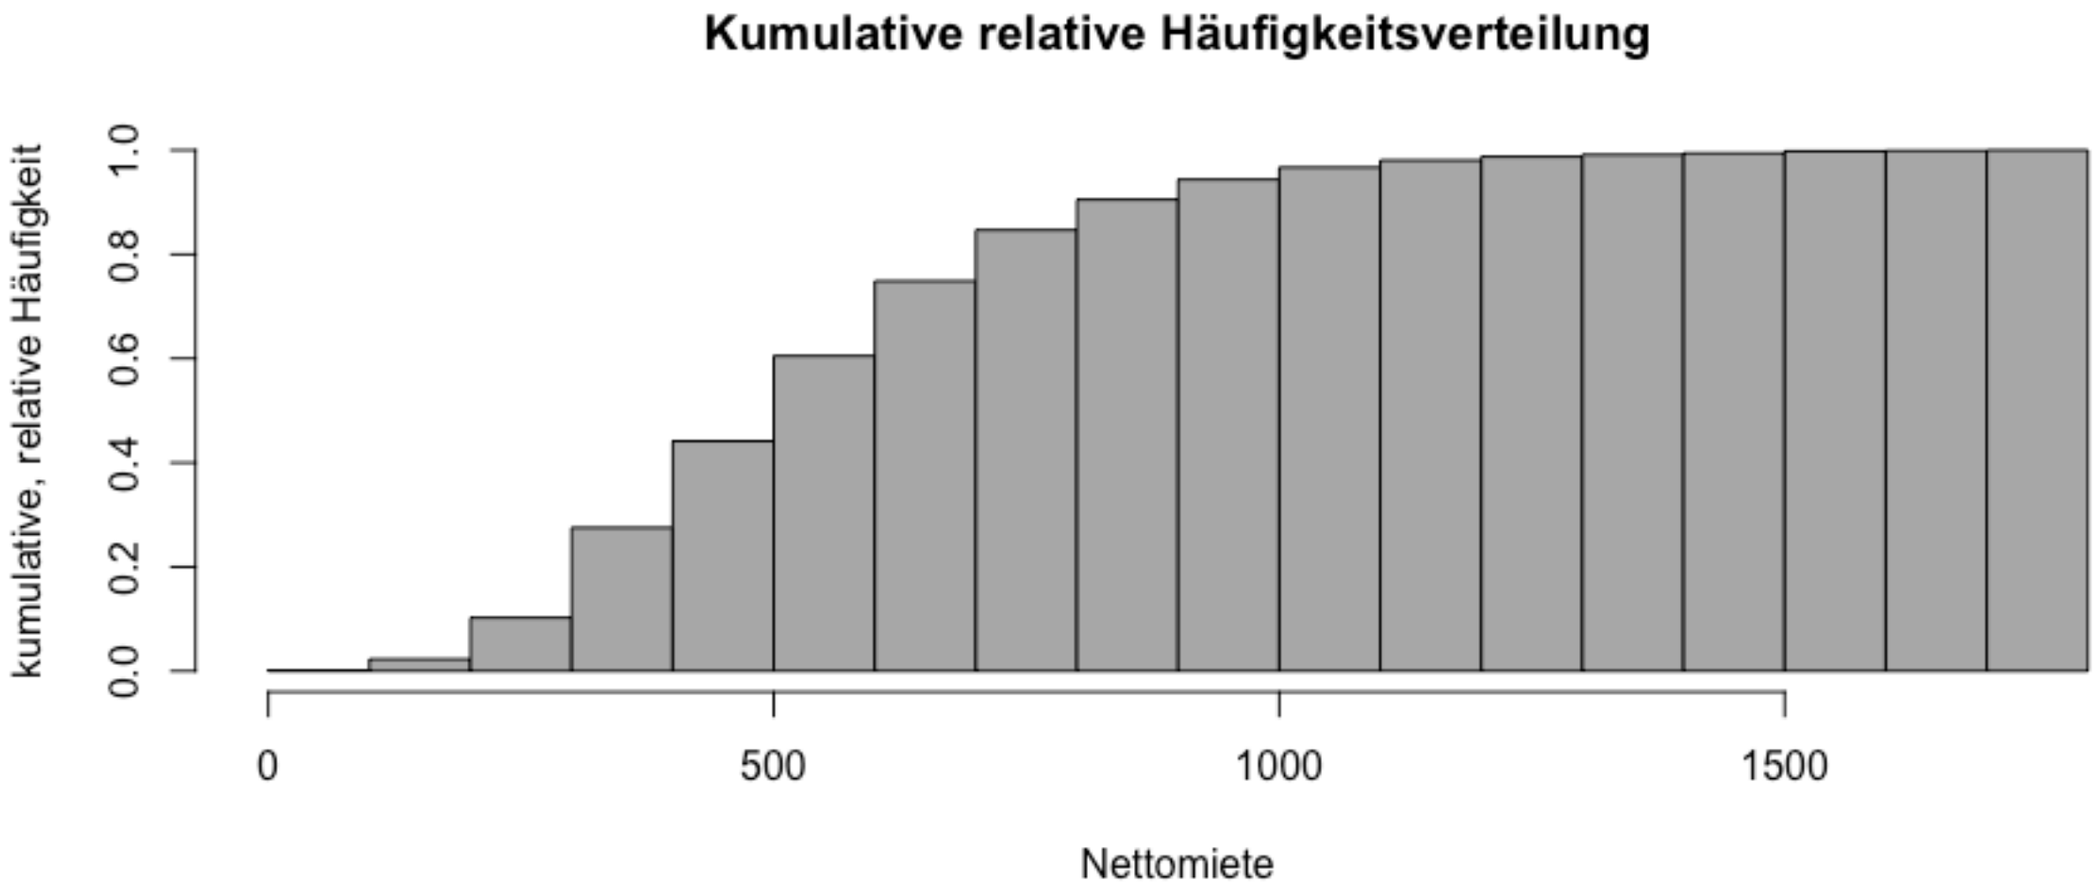


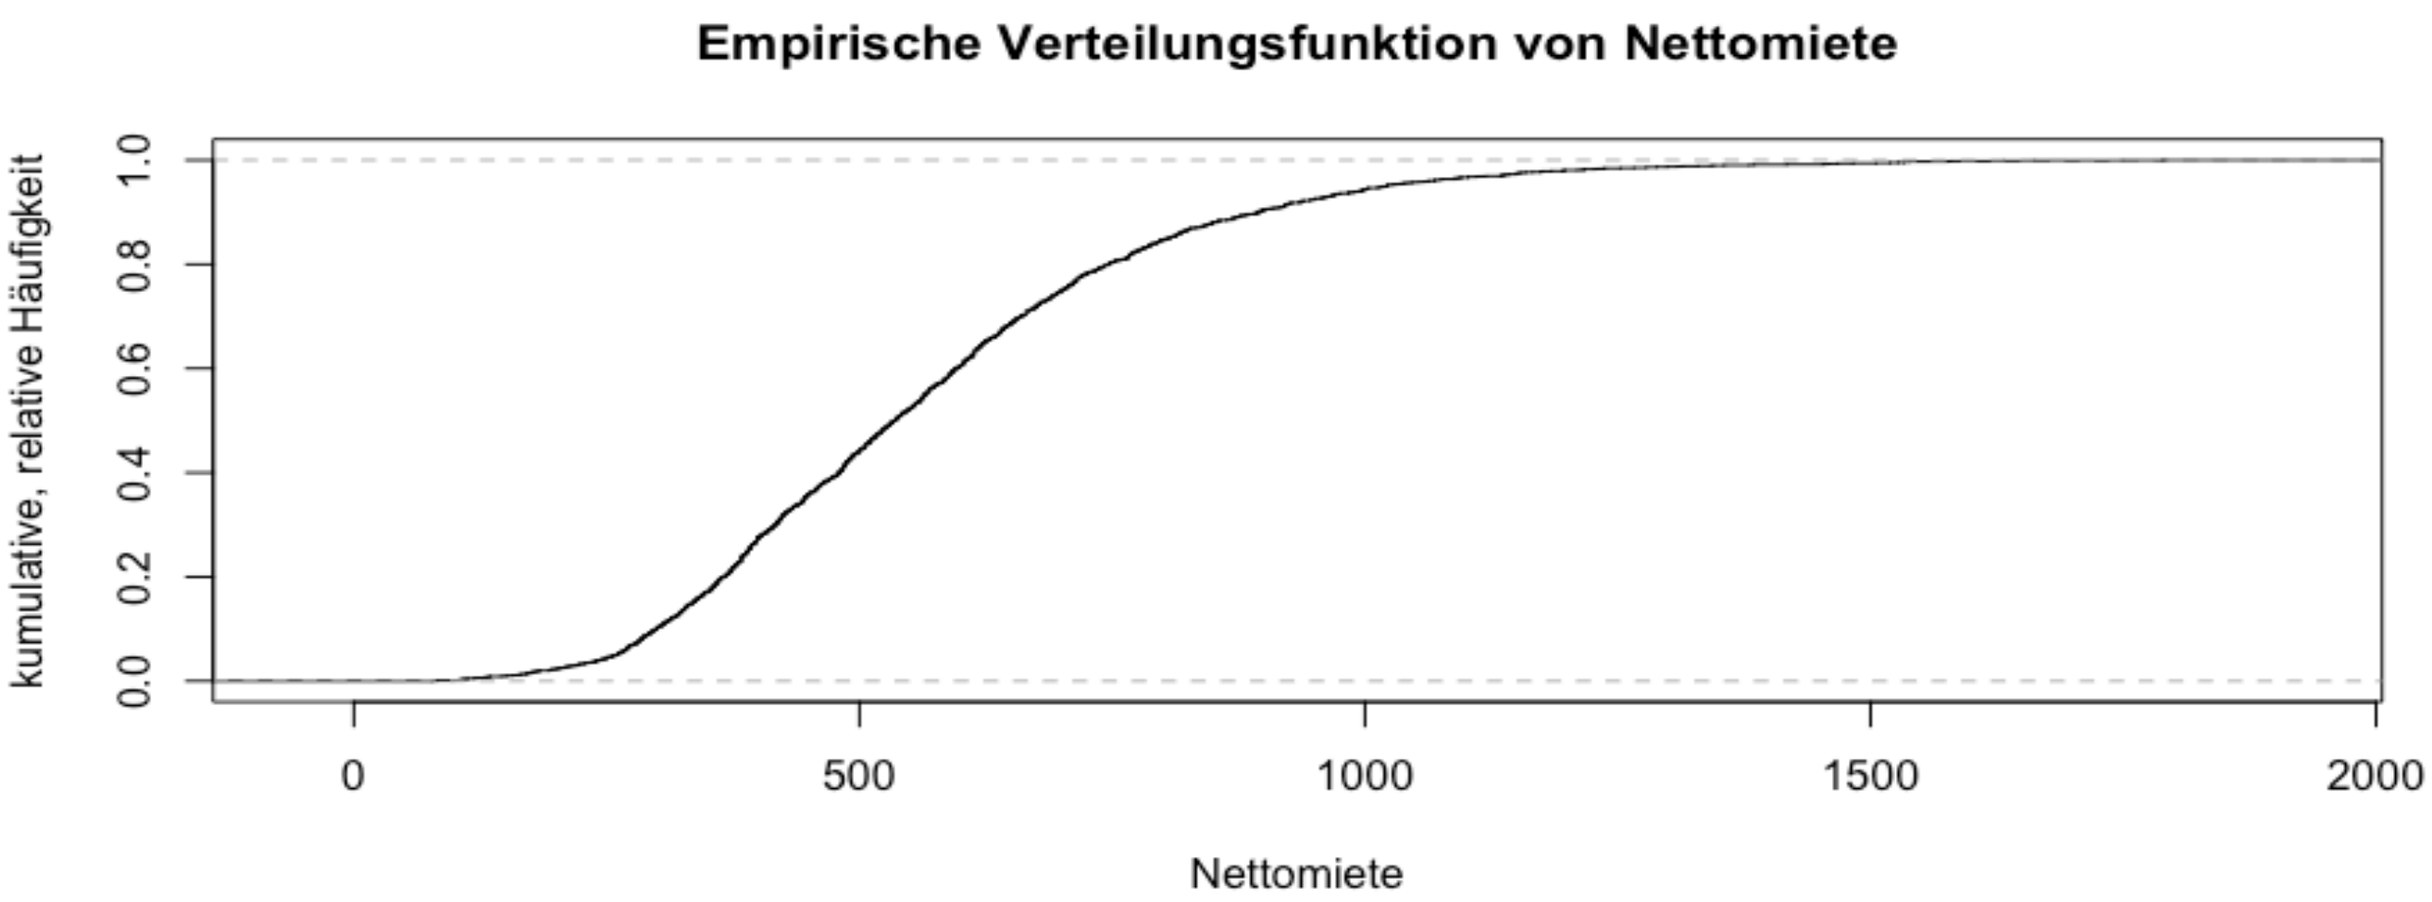
Empirische Verteilungsfunktion

- Statt Klassengrenzen festzulegen, formen die Werte x_i die Grenzen der Klassenintervalle

  [*untere Schranke*, x_1),
  [x_1, x_2),
  [x_2, x_3), ...
  [x_n, *obere Schranke*]

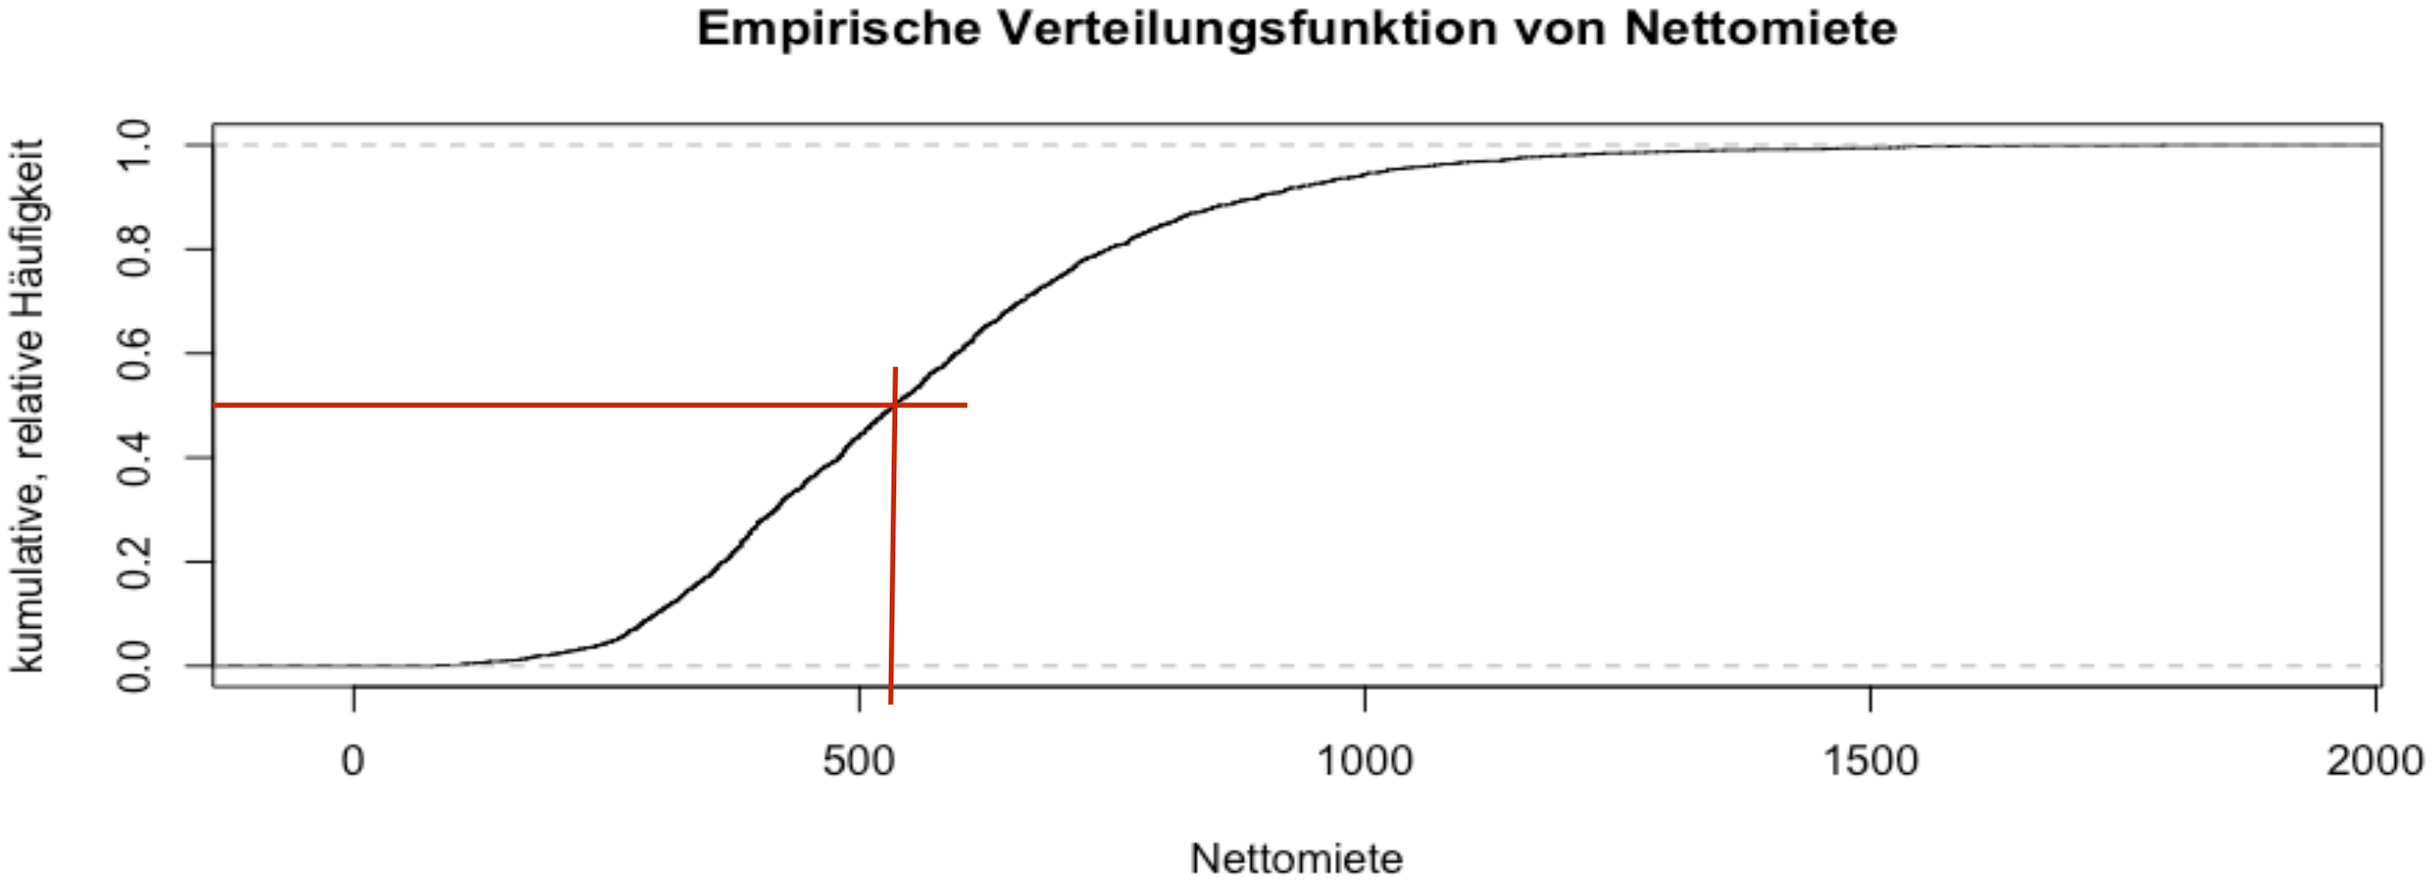
- Je mehr Werte (je größer n) desto feiner die Auflösung
- Untere und obere Schranke definieren den Wertebereich


Kumulative relative Häufigkeitsverteilung
kumulative, relative Häufigkeit
0.0
0.2
0.4
0.6
0.8
1.0
0
500
1000
1500
Nettomiete


Empirische Verteilungsfunktion von Nettomiete
kumulative, relative Häufigkeit
0.0
0.2
0.4
0.6
0.8
1.0
0
500
1000
1500
2000
Nettomiete

Kumulative relative Häufigkeit

Wert *x* ablesen, bei dem *m*% der Merkmalsträger erfasst sind, z.B. bei gut €500 sind 50% erfasst

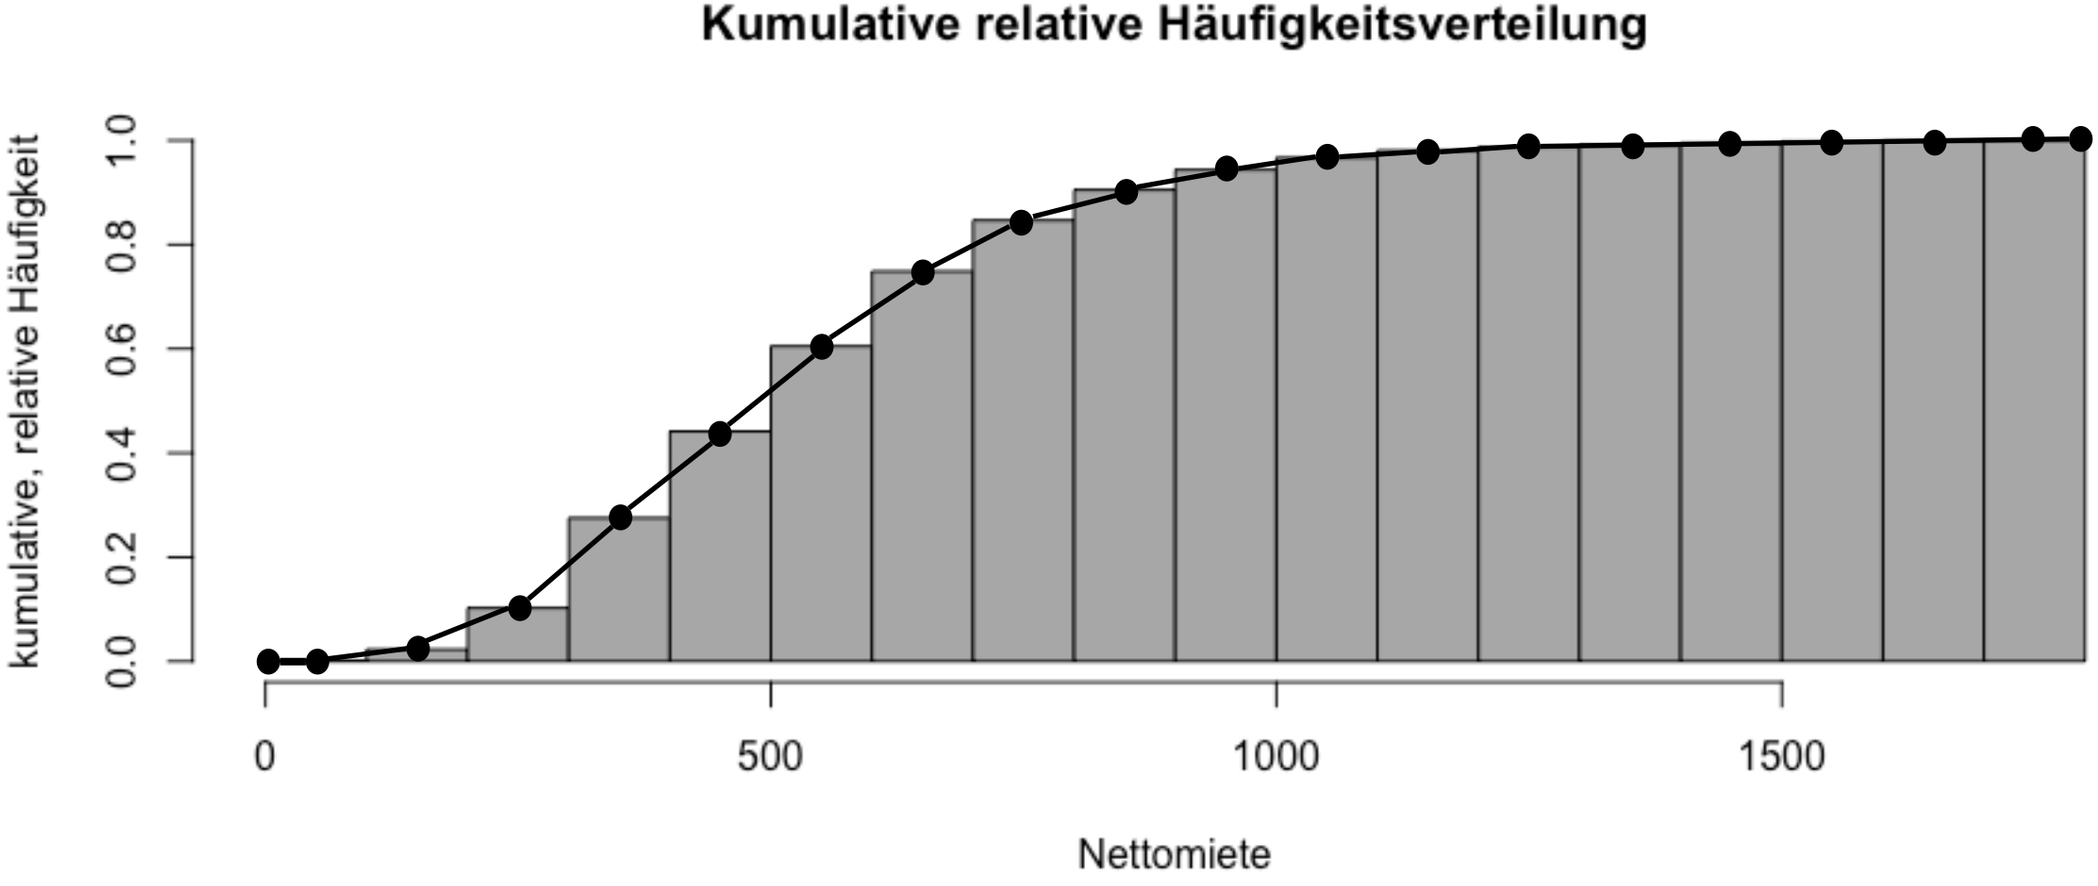


Glattere Kurven durch Polygonzüge I

Bei klassierten Verteilungen können die Mittelpunkte der Klassen zu einem Polygon verbunden werden

Bei kumulativen Verteilungen liegt der Anfangspunkt auf 0, der Endpunkt auf 1

Ergebnis ist eine Approximation einer stetigen Verteilung durch Interpolation, die visuell leichter zu interpretieren ist als die Balken



Glattere Kurven durch Polygonzüge II

Bei empirischen Verteilungsfunktionen werden die Punkte direkt verbunden

