

Hochschule für Technik
und Wirtschaft Berlin

University of Applied Sciences

Statistik für Wirtschaftsinformatik

Pflichtmodul B3.5
Bachelorstudiengang Wirtschaftsinformatik

Prof. Dr. Martin Spott, Data Science

Beschreibungen von Verteilungen durch Maßzahlen

- Grafische Beschreibungen sind nützlich, um einen Eindruck über Lage und Form zu gewinnen

Fragen

- Wo ist das Zentrum der Daten?
- Wie stark streuen die Daten um das Zentrum?
- Gibt es Ausreißer?
- Ist die Verteilung symmetrisch oder schief?

Lagemaße

Arithmetisches Mittel I

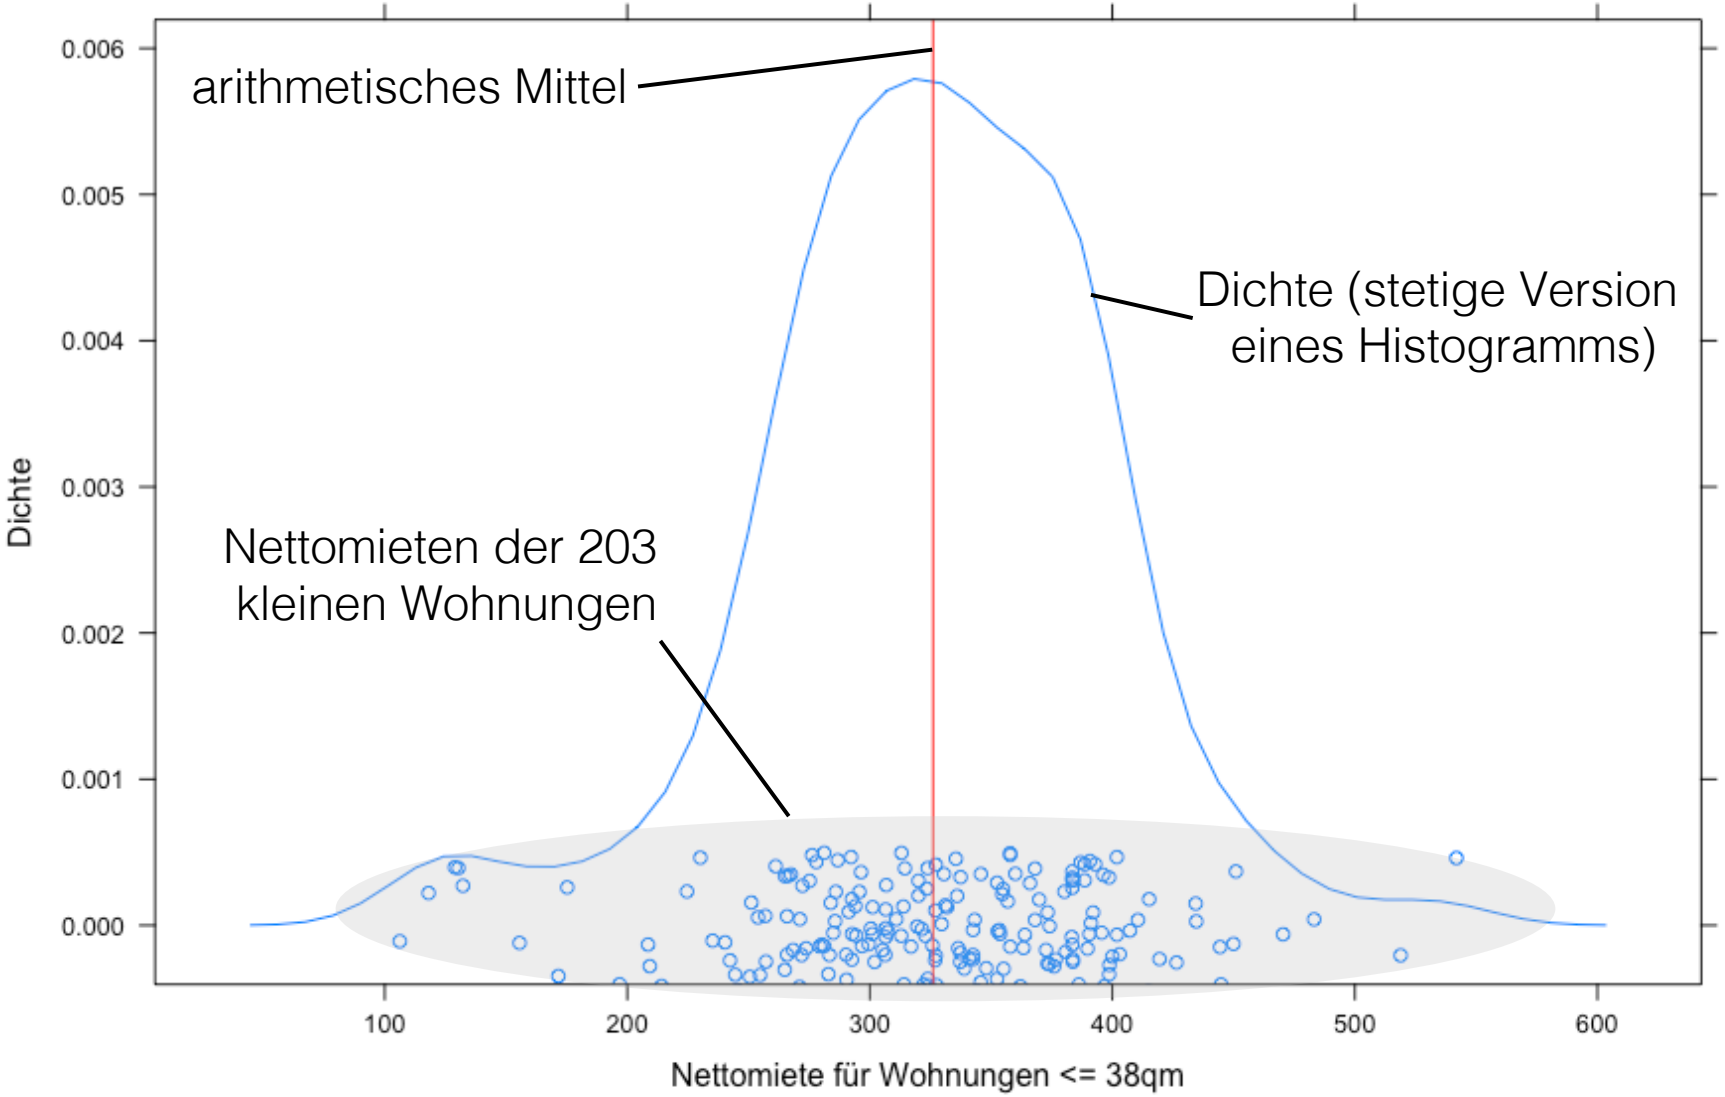
Das ***arithmetische Mittel*** für metrische Merkmale (Intervall- und Verhältnisskala)

wird aus den Rohdaten x_1, x_2, ... x_n berechnet durch

$$\bar{x} = \frac{1}{n}(x_1 + x_2 + \cdots + x_n) = \frac{1}{n}\sum_{i=1}^{n} x_i$$

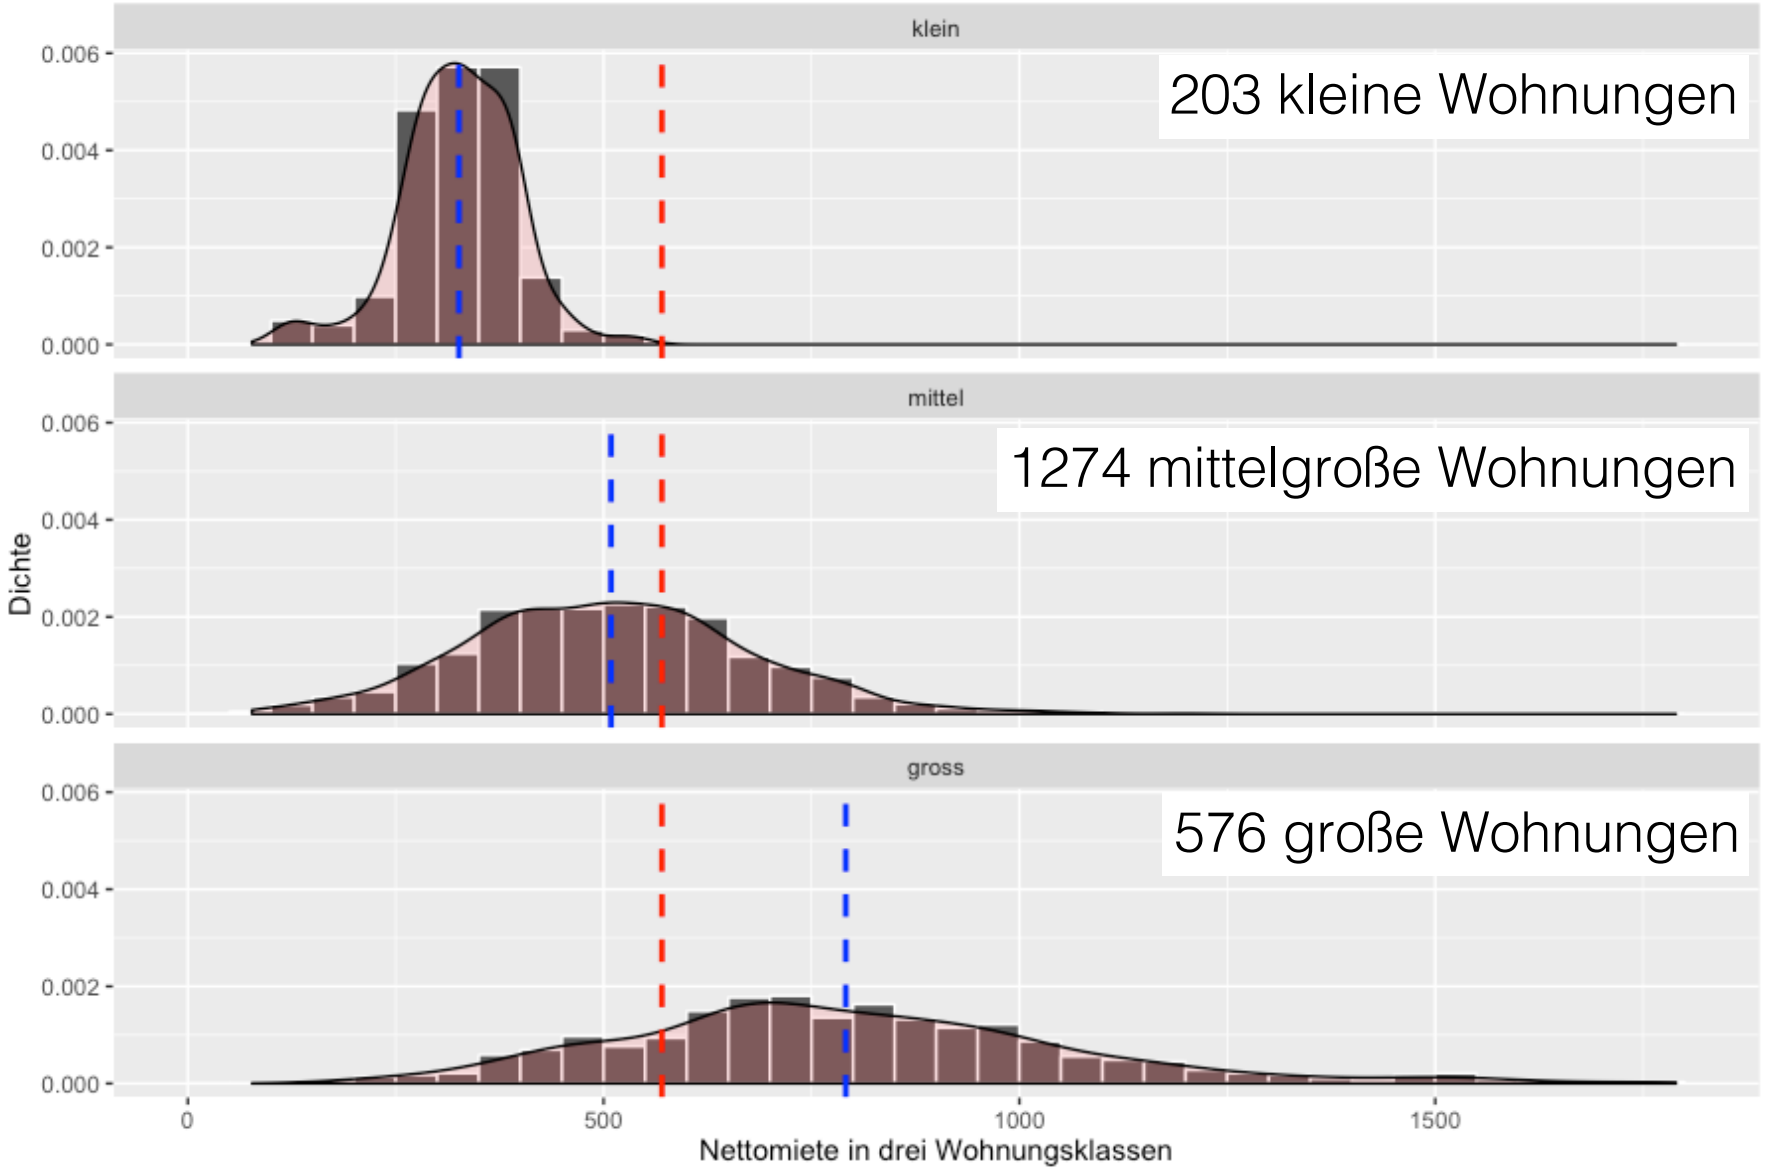
Das arithmetische Mittel kann als Schwerpunkt interpretiert werden.

Arithmetisches Mittel II



Arithmetisches Mittel bei Gruppen I

Gruppenmittelwerte – Gesamtmittelwert



Arithmetisches Mittel bei Gruppen II

Das ***arithmetische Mittel*** kann bei gruppierten Merkmalen auch aus den Mittelwerten der Gruppen berechnet werden. Bei r Gruppen der Größen $n_1, \ldots n_r$ mit arithmetischen Mittelwerten $\bar{x}_1, \bar{x}_2 \ldots \bar{x}_r$

$$\bar{x} = \frac{1}{n}(n_1\,\bar{x}_1 + n_2\,\bar{x}_2 + \cdots + n_r\,\bar{x}_r) = \frac{1}{n}\sum_{i=1}^{r} n_i\,\bar{x}_i$$

Gewichtetes arithmetisches Mittel I

Bei diskreten Merkmalen können wir das arithmetische Mittel aus den Häufigkeiten ausrechnen anstatt die Rohdaten zu benutzen

Beispiel: In einer Umfrage werden n Personen nach dem Alter gefragt. Wir erhalten n Antworten x_i, die aber nur $k < n$ verschiedene Ausprägungen a_j annehmen, welche h_j-mal vorkommen. Für das arithmetische Mittel gilt dann

$$\bar{x} = \frac{1}{n}(h_1\, a_1 + h_2\, a_2 + \cdots + h_k\, a_k) = \frac{1}{n}\sum_{i=1}^{k} h_i\, a_i = \frac{1}{n}\sum_{i=1}^{n} x_i$$

Gewichtetes arithmetisches Mittel II

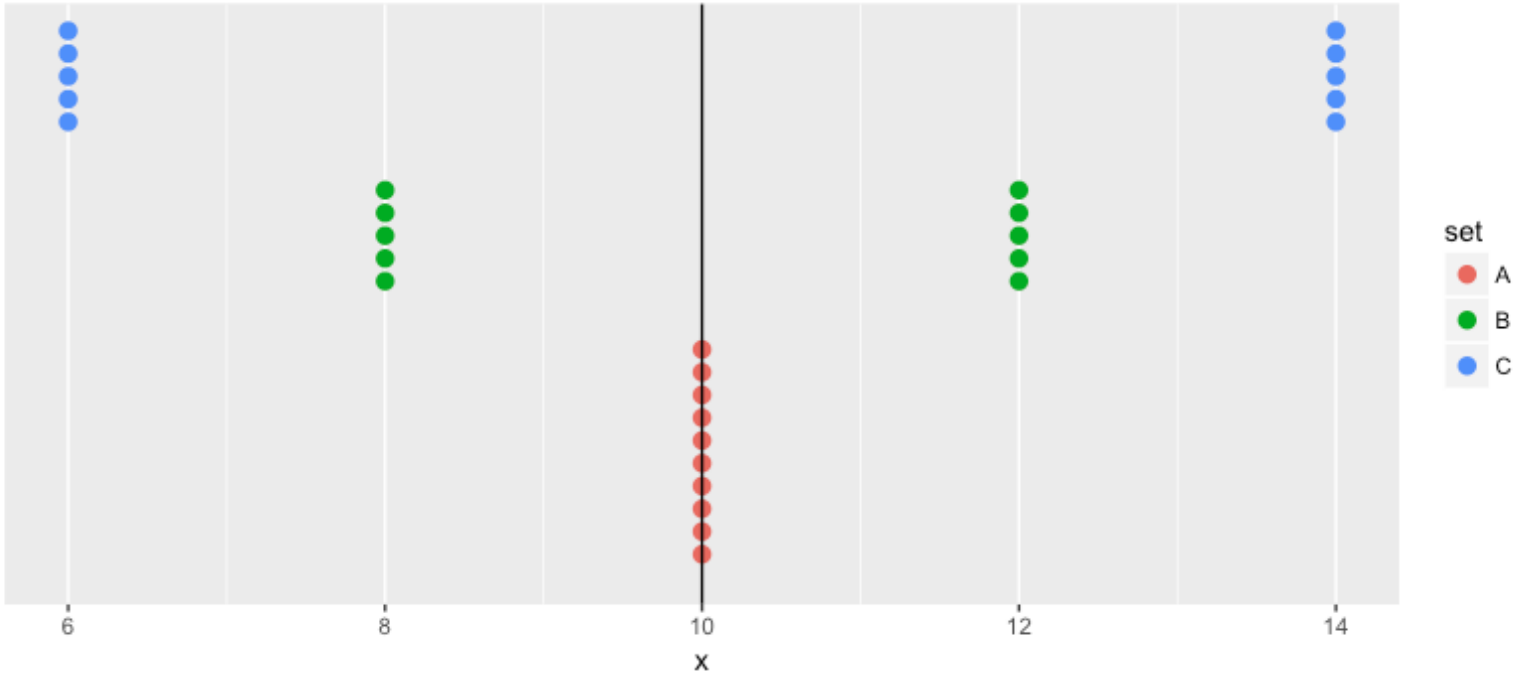
In anderen Fällen ordnet man den Ausprägungen a_j direkt Gewichte zu, die z.B. die Wichtigkeit der Ausprägungen widerspiegeln.

Beispiel: Verschiedene Fächer im Studium werden verschieden gewichtet und die Noten dementsprechend durch ein gewichtetes arithmetisches Mittel berechnet.

Eigenschaften des arithmetischen Mittels I

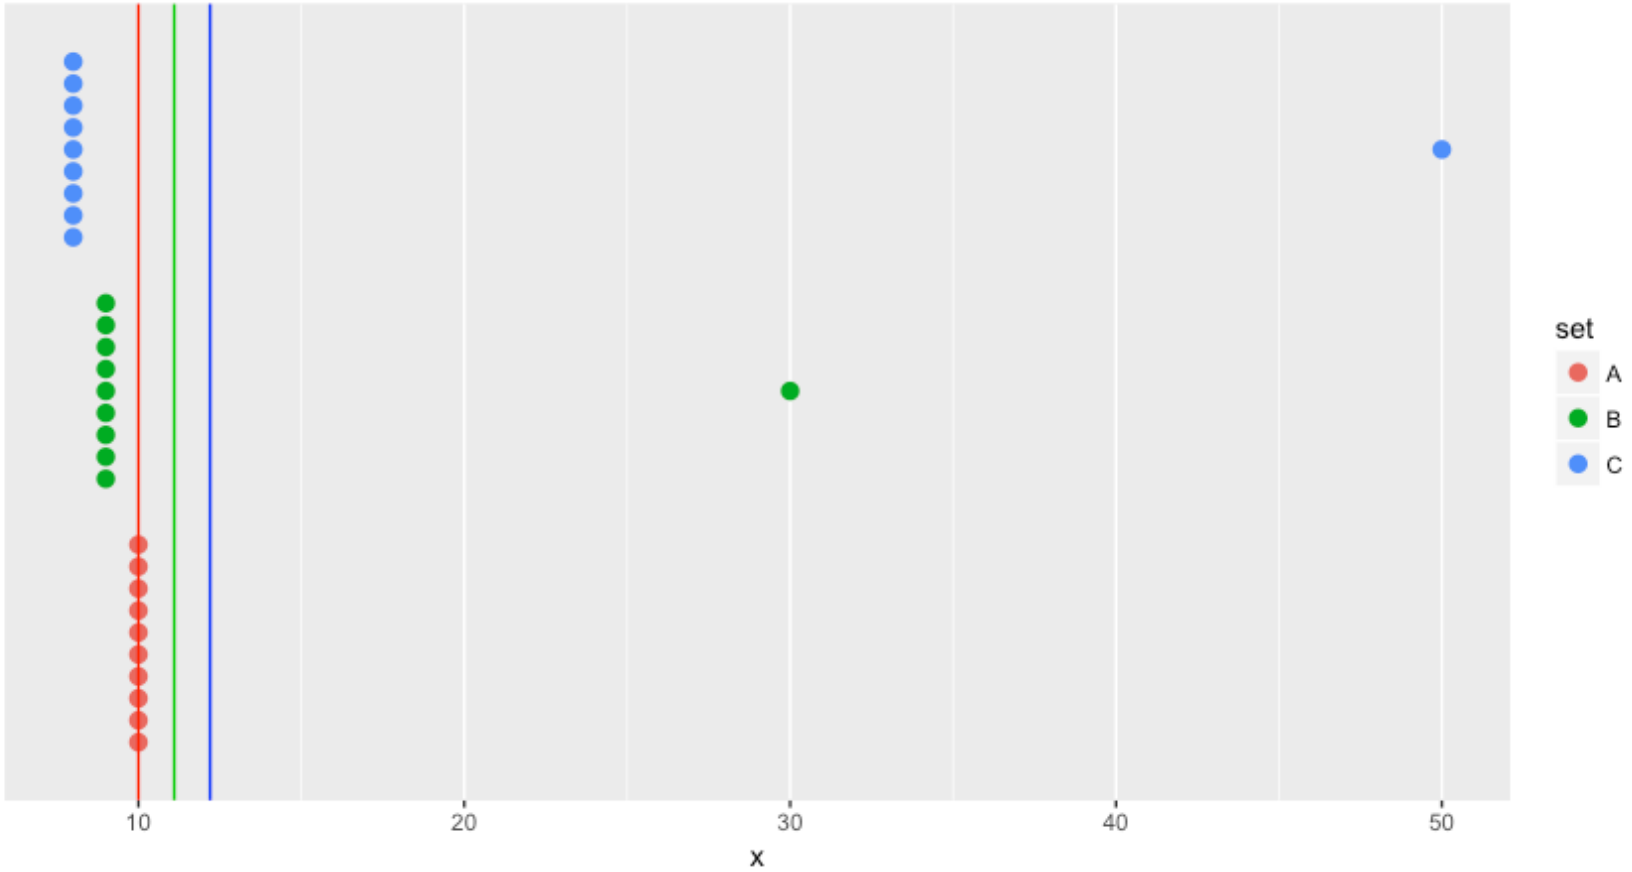
Wert ändert sich nicht mit der Breite der Werteverteilung

Rote, grüne und blaue Wertemengen haben alle 10 als arithmetischen Mittelwert



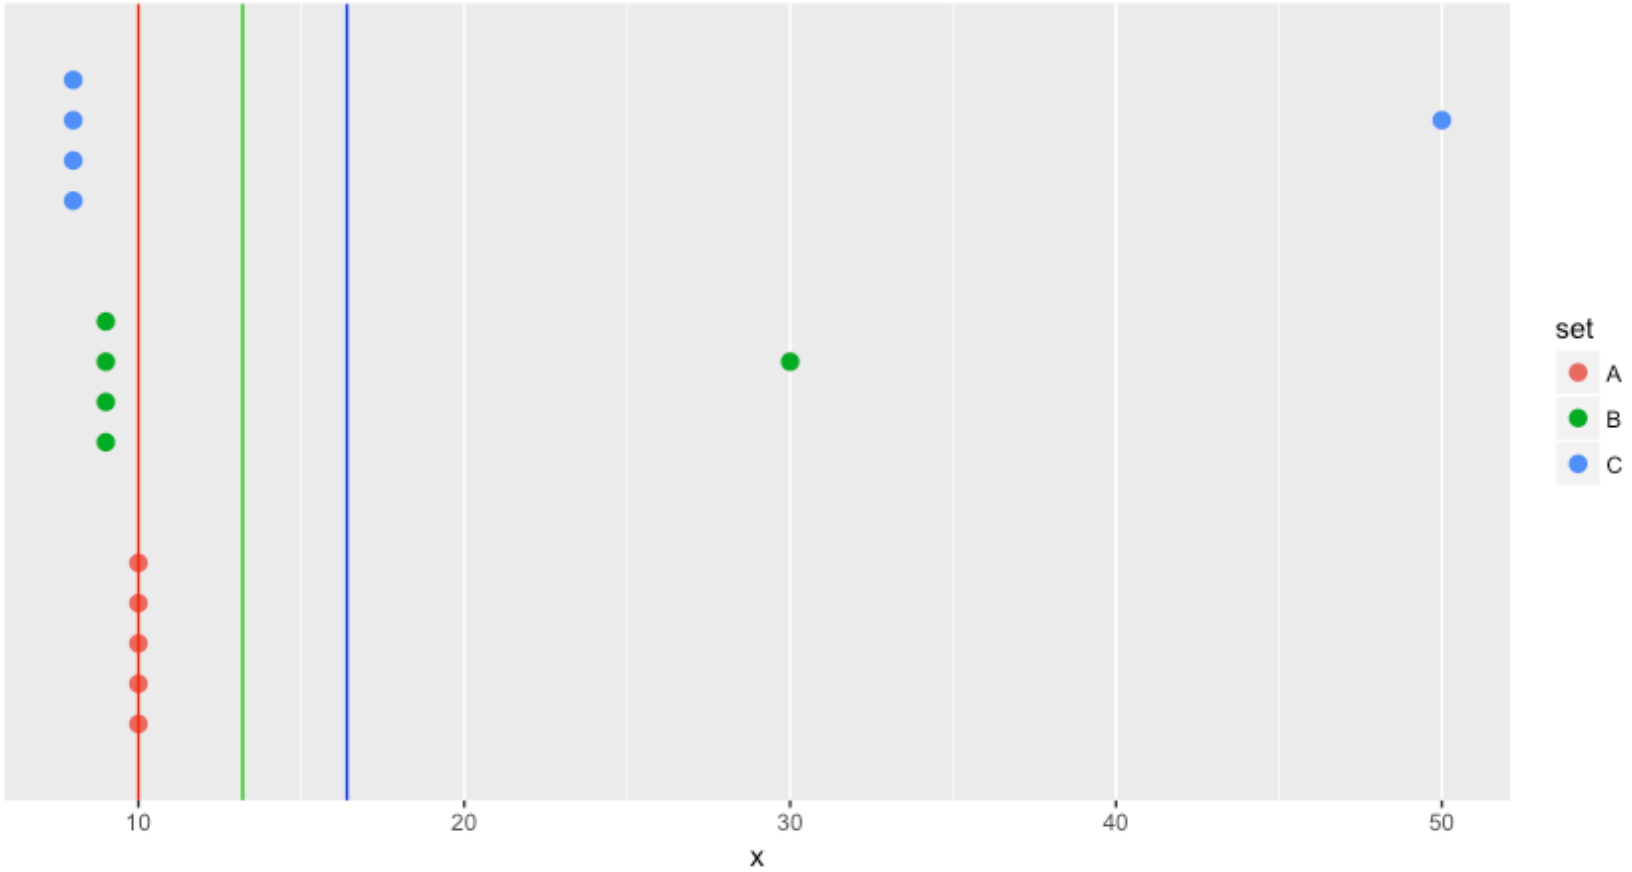
Eigenschaften des arithmetischen Mittels II

Empfindlich gegenüber Ausreißern



Eigenschaften des arithmetischen Mittels III

Empfindlich gegenüber Ausreißern, extremer bei kleinen Grundgesamtheiten



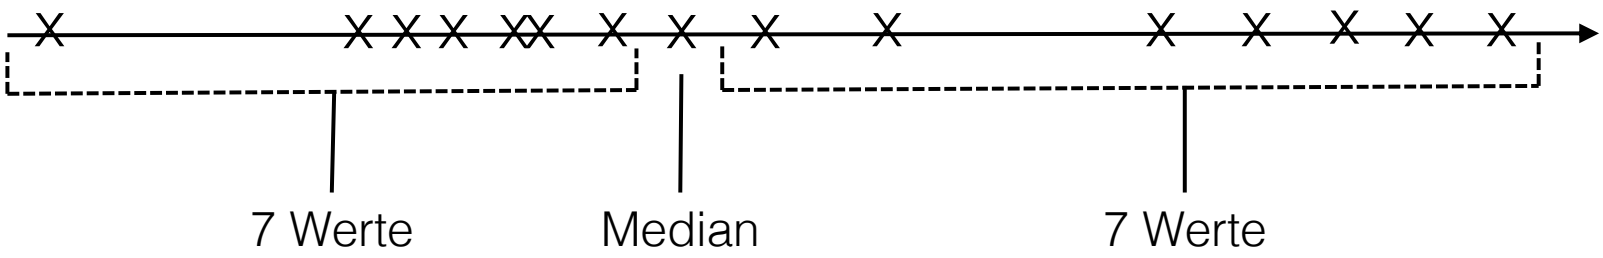
Getrimmtes arithmetisches Mittel

Um den Einfluss von Ausreißern auf das arithmetische Mittel zu reduzieren, kann man einen Teil der Randdaten bei der Berechnung weglassen

- pauschal z.B. 10% der Randdaten weglassen
- Daten gezielt auf Ausreißer analysieren und diese weglassen. Wir werden später Techniken dazu kennen lernen

Median I

- Der „mittlere“ Wert einer geordneten Liste von Werten
- 50% der Werte sind kleiner oder gleich dem Median und 50% sind größer oder gleich
- Beispiel mit 15 Werten



- Die Werte spielen bei der Bestimmung des Medians keine Rolle, es geht nur um die Position in der geordneten Liste
- Man kann also Werte auf beiden Seiten des Medians beliebig verändern, ohne dass sich der Median ändert

Median II

Für ungerades n ist der Median x_{med} die mittlere Beobachtung der geordneten Rohdaten und für gerades n ist der Median x_{med} das arithmetische Mittel der beiden in der Mitte liegenden Beobachtungen, d.h.

$$x_{med} = \begin{cases} x_{\frac{n+1}{2}} & \text{für ungerade } n \\ \frac{1}{2}\left(x_{n/2} + x_{n/2+1}\right) & \text{für gerade } n \end{cases}$$

Die Berechnungsvorschrift ist auch gültig, wenn mehrere der x_i denselben Wert haben.

Arithmetisches Mittel versus Median

- Median ist robust gegenüber Ausreißern
- Median ist besser bei schiefen Verteilungen
- Das arithmetische Mittel minimiert die Summe der quadratischen Abweichungen, d.h.

$$\sum_{i=1}^{n}(x_i - \bar{x})^2 \leq \sum_{i=1}^{n}(x_i - z)^2 \quad \text{für alle } z \neq \bar{x}$$

- Der Median minimiert die Summe der absoluten Abweichungen

$$\sum_{i=1}^{n}|x_i - x_{med}| \leq \sum_{i=1}^{n}|x_i - z| \quad \text{für alle } z \neq x_{med}$$

Modus I

Der ***Modus*** oder ***Modalwert*** x_{mod} ist die Ausprägung mit größter Häufigkeit.

Der Modus ist eindeutig, falls die Häufigkeitsverteilung ein eindeutiges Maximum besitzt.

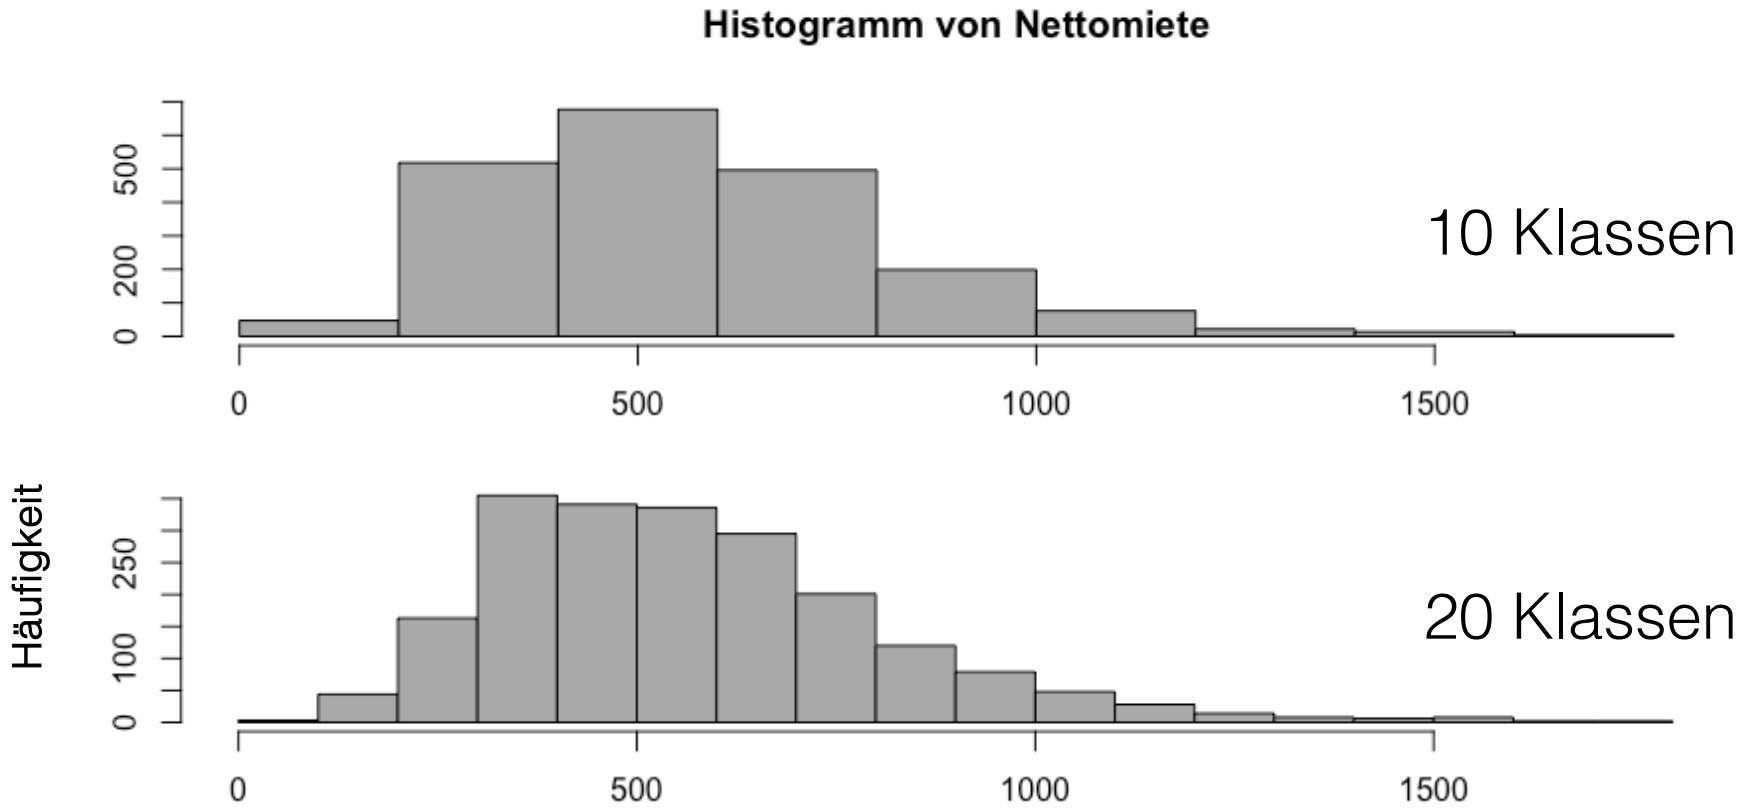
Modus ist das wichtigste Lagemaß für qualitative Merkmale und schon bei Nominalskalen sinnvoll.

Modus II

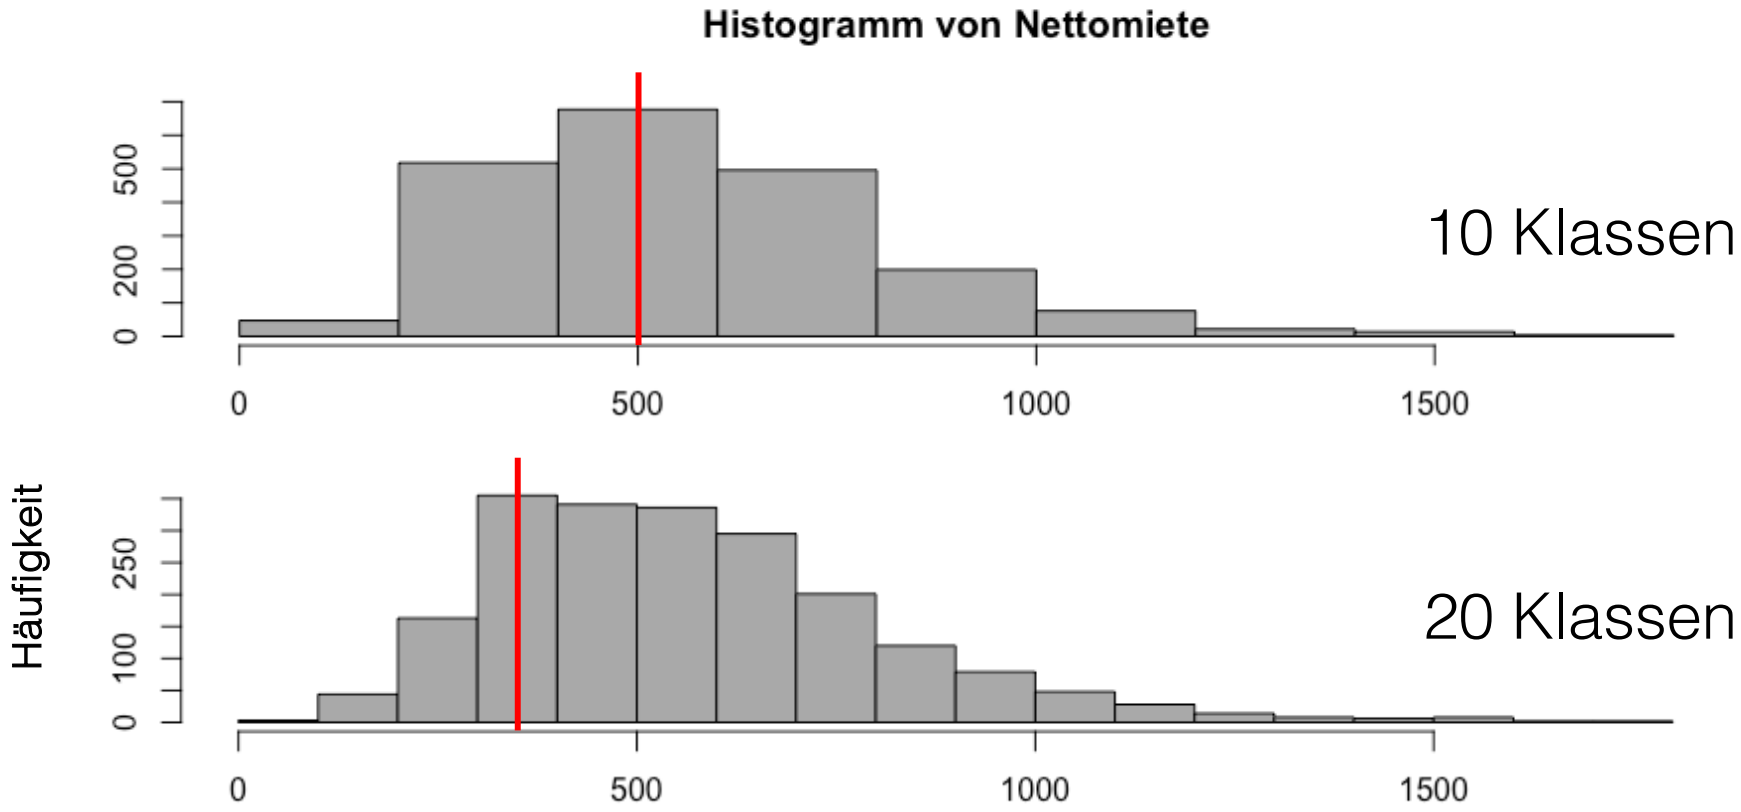
- Für stetige Merkmale ist der Modus als Lagemaß der Rohdaten nicht sinnvoll, da Ausprägungen oft nur einmal vorkommen

- In diesem Fall kann man den Modus auf gruppierten Daten berechnen:
  - finde die Gruppe i mit der größten Häufigkeitsdichte h_i / d_i (absolute Dichte) bzw. f_i / d_i (relative Dichte)
  - berechne den Modus als Mitte der Gruppe i aus ihren Grenzen $x_{mod} = (c_i - c_{i-1}) / 2$

Modus gruppierter Merkmale



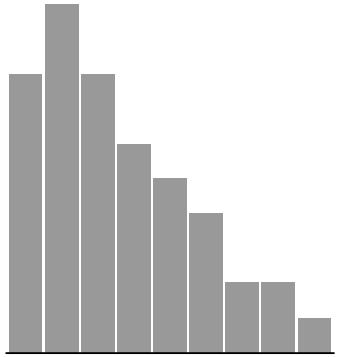
Modus gruppierter Merkmale



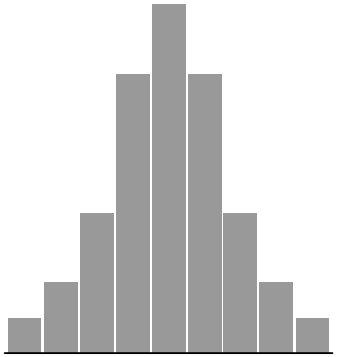
- starke Abhängigkeit von der Gruppierung, daher nur eingeschränkt nützlich

Lageregeln

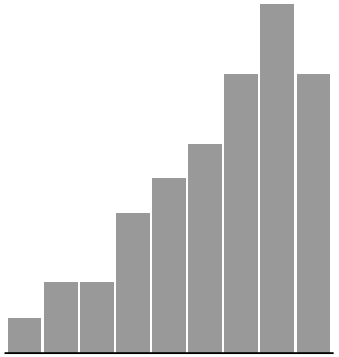
Die relative Lage von arithmetischem Mittel, Median und Modus kann dazu benutzt werden, um den Grad der Schiefe einer Verteilung zu beurteilen



linkssteil



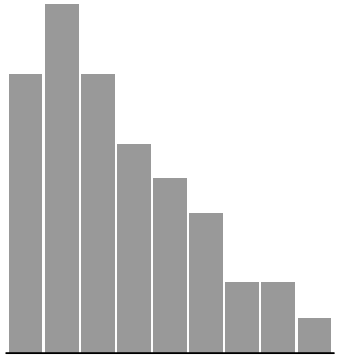
symmetrisch



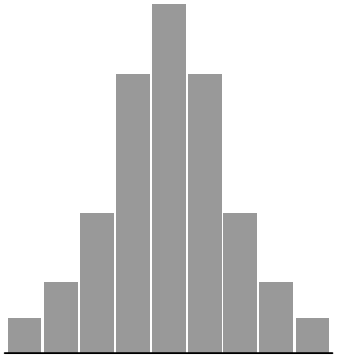
rechtssteil

Lageregeln

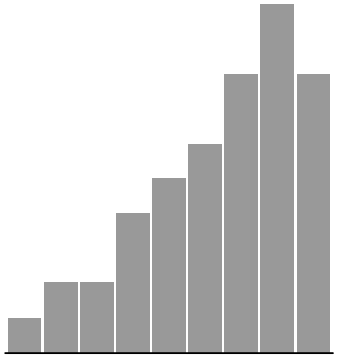
Die relative Lage von arithmetischem Mittel, Median und Modus kann dazu benutzt werden, um den Grad der Schiefe einer Verteilung zu beurteilen



linkssteil



symmetrisch



rechtssteil

Symmetrische Verteilungen:	$\bar{x} \approx x_{med} \approx x_{mod}$
Linkssteile Verteilungen:	$\bar{x} > x_{med} > x_{mod}$
Rechtssteile Verteilungen:	$\bar{x} < x_{med} < x_{mod}$

Geometrisches Mittel I

Werden Wachstumsfaktoren über mehrere Zeitperioden beobachtet, so sind arithmetisches Mittel und Median ungeeignet, um das durchschnittliche Wachstum zu berechnen.

Grund dafür ist, dass Wachstumsfaktoren multipliziert werden, um das Gesamtwachstum zu berechnen.

In diesem Fall ist das geometrische Mittel zu benutzen.

Geometrisches Mittel II

Ausgehend von einem Anfangsbestand B_0 sei $B_0, B_1, \ldots, B_n$ eine Zeitreihe von Bestandsdaten in den Perioden $0, 1, \ldots, n$. Dann ist für $i = 1, \ldots, n$

$$x_i = B_i / B_{i-1}$$

der i-te *Wachstumsfaktor* und

$$r_i = \frac{B_i - B_{i-1}}{B_{i-1}} = x_i - 1$$

die i-te *Wachstumsrate*. Damit gilt

$$B_n = B_0 x_1 \cdot \ldots \cdot x_n \,.$$

Das *geometrische Mittel* zu den Faktoren $x_1, \ldots, x_n$ ist

$$\bar{x}_{geom} = (x_1 \cdot \ldots \cdot x_n)^{1/n} \,.$$

Beispiel Durchschnittsgeschwindigkeit

Wir fahren 10km lang mit 20km/h und dann 10km lang mit 40km/h. Was ist die Durchschnittsgeschwindigkeit über die 20km lange Strecke?

Beispiel Durchschnittsgeschwindigkeit

Wir fahren 10km lang mit 20km/h und dann 10km lang mit 40km/h. Was ist die Durchschnittsgeschwindigkeit über die 20km lange Strecke?

Für die erste Strecke brauchen wir 10km / 20km/h = 1/2h, für die zweite 10km / 40km/h = 1/4h, insgesamt also 3/4h. Die Durchschnittsgeschwindigkeit ist damit 20km / 3/4h = (80 / 3) km/h = 26.7km/h und **nicht** das arithmetische Mittel 30km/h.

Zusammen:

$$x = \frac{10 + 10}{\frac{10}{20} + \frac{10}{40}} = \frac{0.5 + 0.5}{\frac{0.5}{20} + \frac{0.5}{40}} = \frac{1}{\frac{1}{2}\left(\frac{1}{20} + \frac{1}{40}\right)}$$

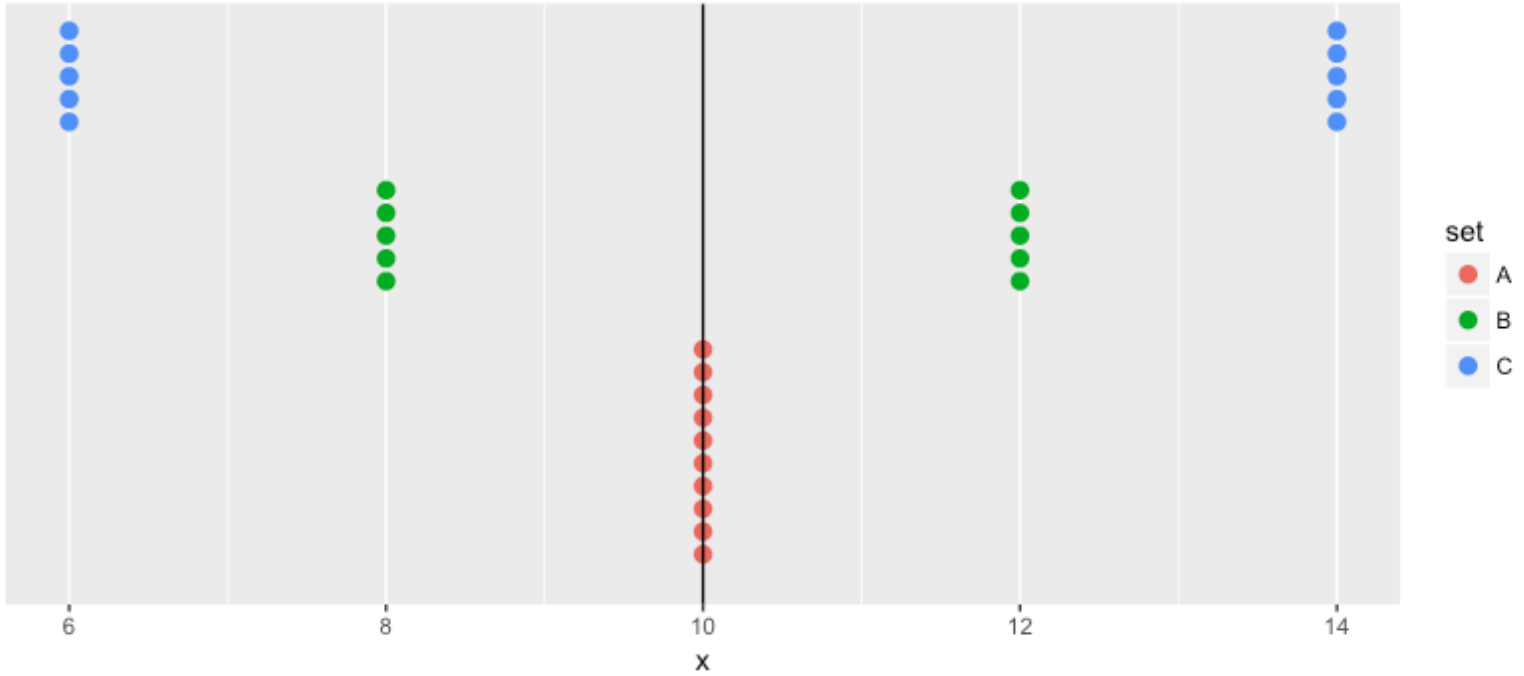
Harmonisches Mittel

Seien den Werten x_i, $i = 1, 2, \ldots n$, Gewichte w_i zugeordnet. Das ***harmonische Mittel*** berechnet man dann als

$$x_{har} = \frac{w_1 + w_2 + \cdots + w_n}{\frac{w_1}{x_1} + \frac{w_2}{x_2} + \cdots + \frac{w_n}{x_n}}$$

Streuungsmaße

- Lagemaße beschreiben nur die Lage des Zentrums einer Werteverteilung, sagen aber nichts über die Breite der Streuung aus
- Zur Erinnerung: das arithmetische Mittel ist für die blauen, grünen und roten Mengen identisch, obwohl sie sich deutlich unterscheiden



Minimum, Maximum, Spannweite

Elementare Messungen zur Streuung einer Erhebung sind

- ***Minimum*** x_{min} (kleinster Wert)
- ***Maximum*** x_{max} (größter Wert)

Minimum und Maximum für sich genommen messen nicht die Streuung, dafür aber die

- ***Spannweite*** = Maximum – Minimum

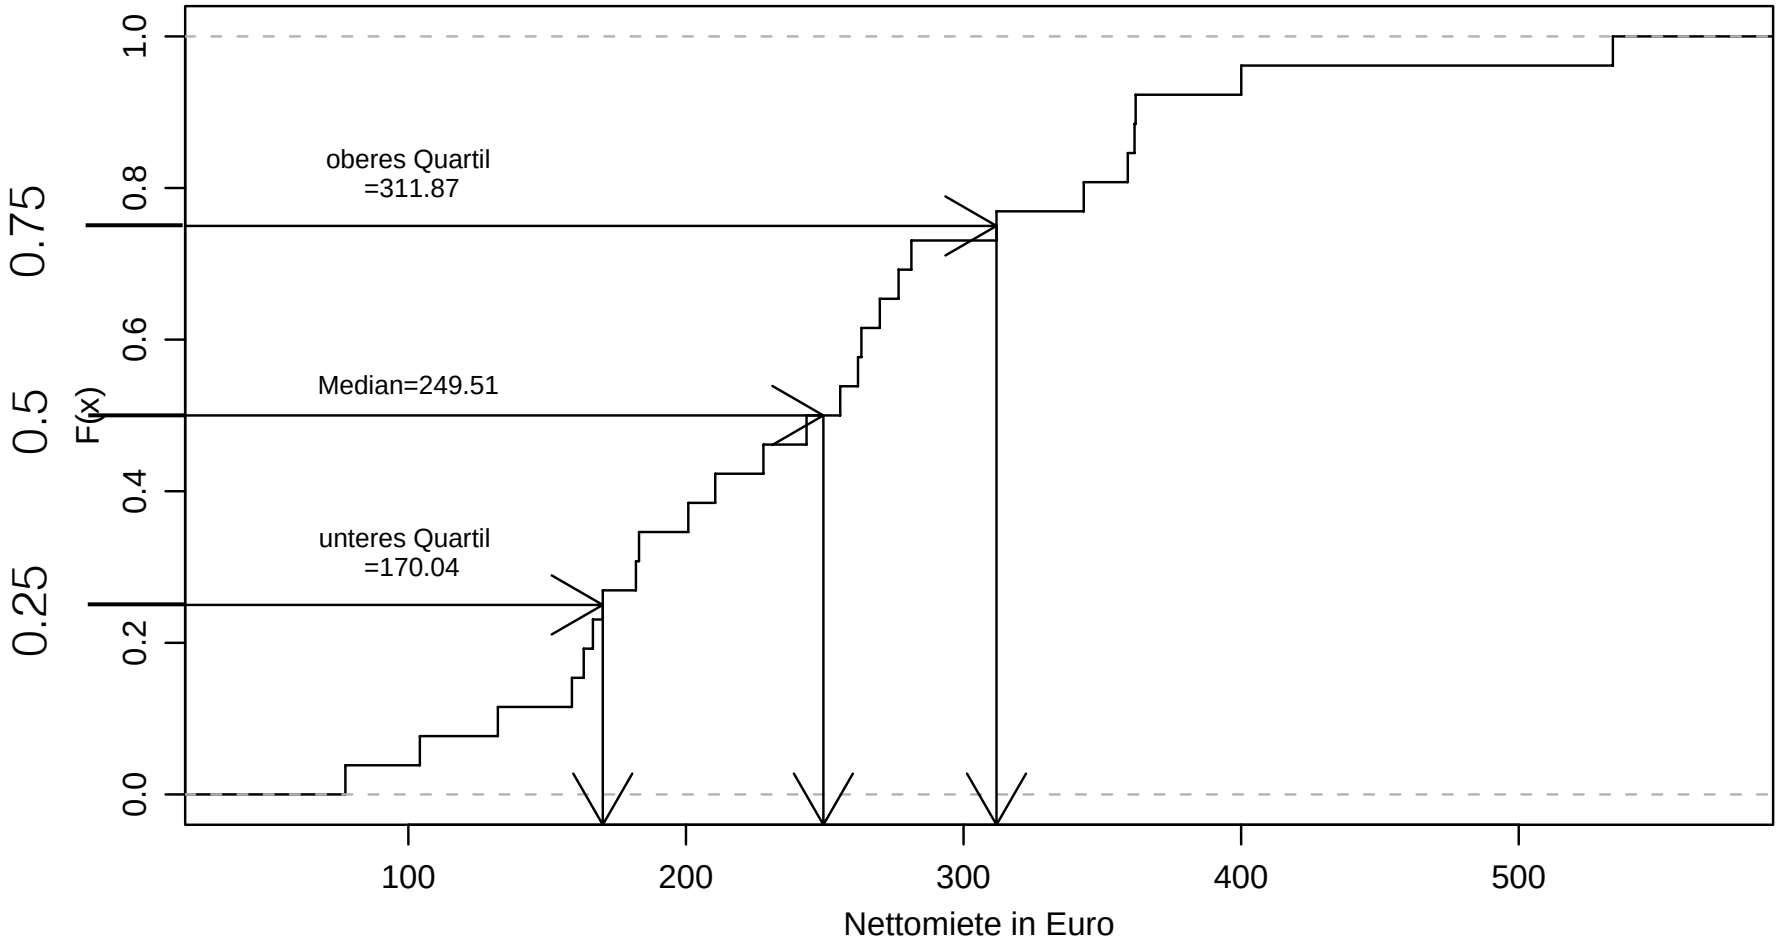
Quantile

Eine Zahl q_p mit $0 < p < 1$ heißt ***p-Quantil***, wenn sie die Werte $x_1, x_2, \ldots x_n$ so aufteilt, dass mindestens $100 \cdot p\,\%$ der Werte kleiner oder gleich q_p sind und gleichzeitig mindestens $100 \cdot (1 - p)\%$ größer oder gleich q_p sind.

Besondere (bzw. häufig verwendete) Quantile sind:
$Q_1 = q_{0,25} =$ ***unteres*** oder ***erstes Quartil***
$Q_2 = q_{0,5} =$ ***zweites Quartil*** oder ***Median***
$Q_3 = q_{0,75} =$ ***drittes Quartil***

Beachte den Unterschied zwischen Quantil und Quartil. Eine Aufteilung in 10 oder 100 Anteilswerte führt zu ***Dezilen*** oder ***Perzentilen***.

Quartile an kumulativer Verteilung ablesen



Fünf-Punkte-Zusammenfassung

Die Quartile, das Minimum, Maximum sowie der Median teilen den Datensatz in vier Teile, wobei jeder dieser Teile in etwa ein Viertel der Beobachtungswerte enthält. Dies gibt ebenfalls Information über die Verteilung der Beobachtungen.

Die Angabe dieser fünf Werte

x_{min}, $q_{0,25}$, $q_{0,5} = x_{med}$ *(Median)*, $q_{0,75}$, x_{max}

wird auch als ***Fünf-Punkte-Zusammenfassung*** bezeichnet.

Interquartilsabstand (IQR)

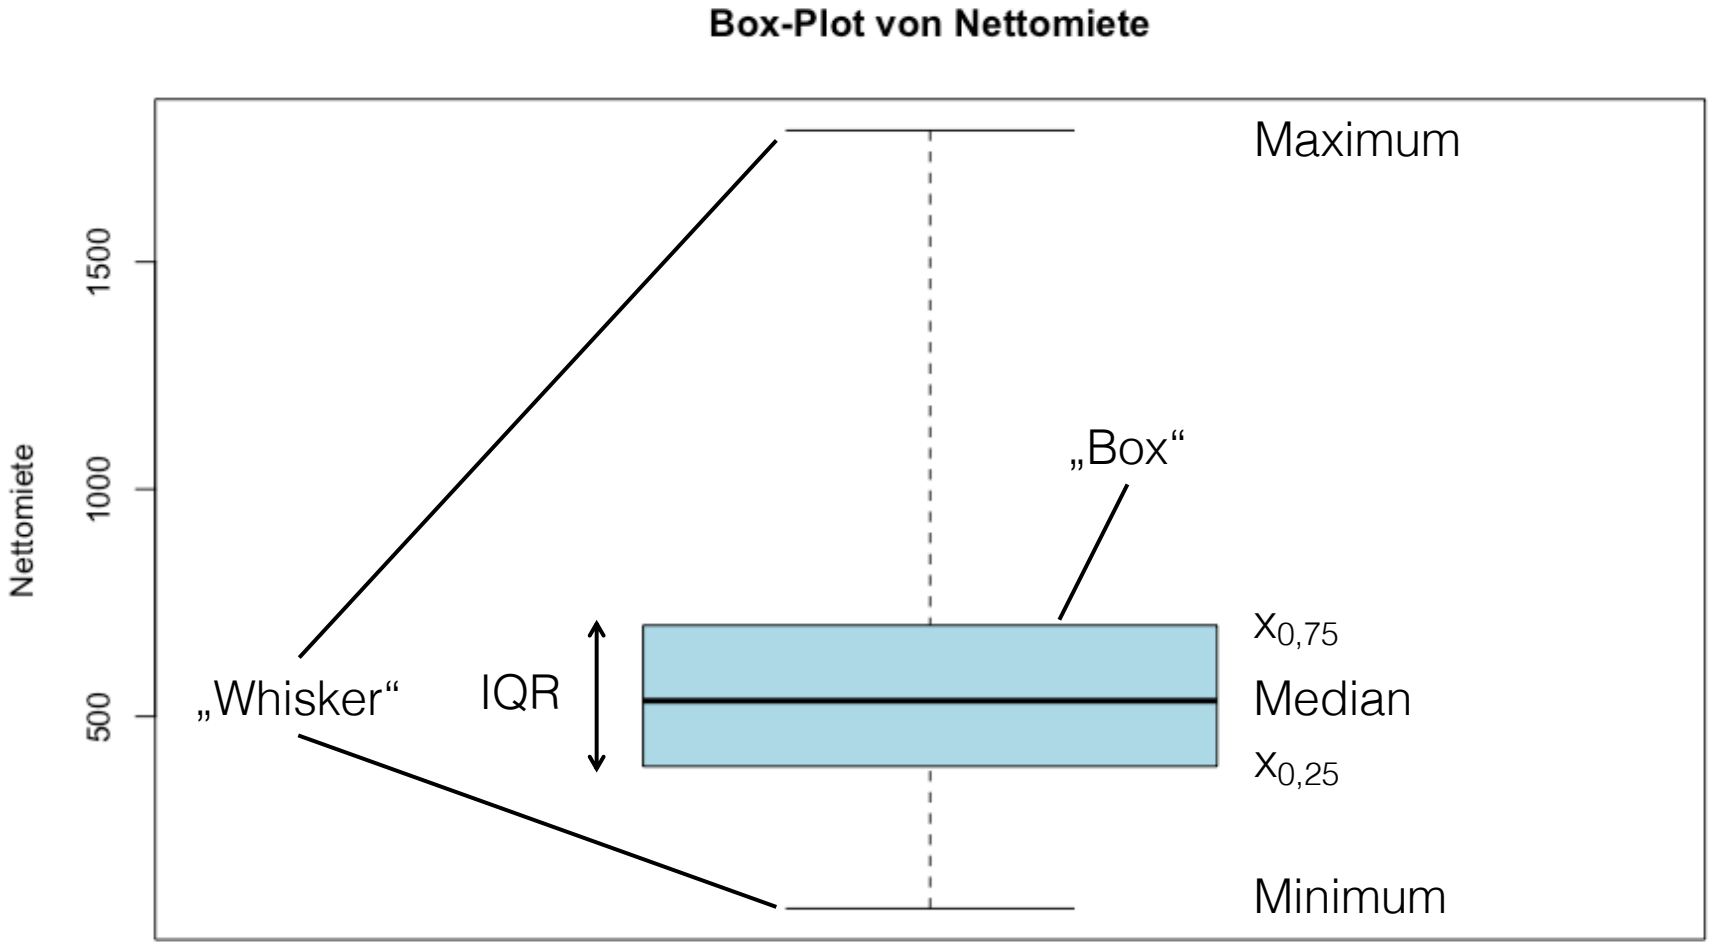
Der ***Interquartilsabstand*** ist der Abstand zwischen erstem Quartil $q_{0,25}$ und drittem Quartil $q_{0,75}$, d.h.

$$IQR = q_{0,75} - q_{0,25}$$

IQR steht für den englischen Begriff *Interquartile Range*. Der Abstand misst die Breite oder Streuung der mittleren 50% der Daten.

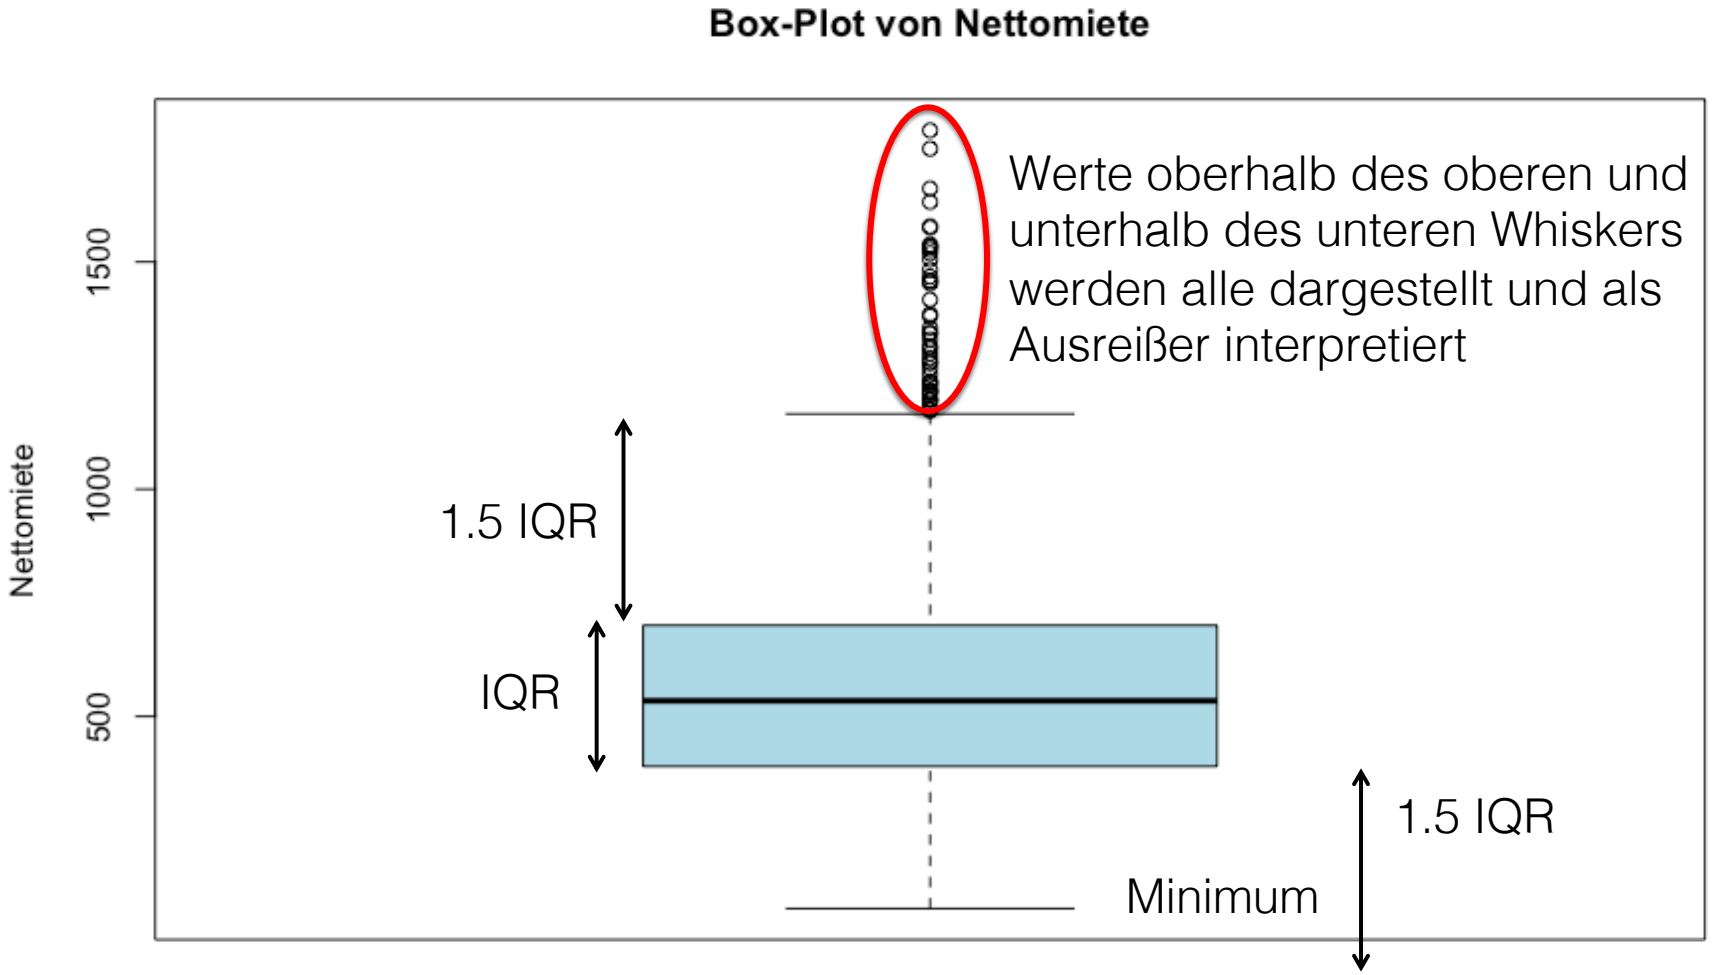
Box-Plots – einfache Version

Die einfache Version visualisiert die Fünf-Punkte-Zusammenfassung



Box-Plot – erweiterte Version

Die erweiterte (übliche) Version setzt die Whisker an die Positionen $\max(x_{min}, q_{0,25} - 1.5\ IQR)$ und $\min(x_{max}, q_{0,75} + 1.5\ IQR)$



Mittlere absolute Abweichung

Die ***mittlere absolute Abweichung*** $\tilde{d}$ der Werte $x_1, x_2, \ldots x_n$ vom arithmetischen Mittel $\bar{x}$ ist wie folgt definiert:

$$\tilde{d} = \frac{1}{n}\left(|x_1 - \bar{x}| + \cdots + |x_n - \bar{x}|\right) = \frac{1}{n}\sum_{i=1}^{n}|x_i - \bar{x}|$$

Für Häufigkeitsdaten mit relativen Häufigkeiten f_j gilt

$$\tilde{d} = |a_1 - \bar{x}|f_1 + \cdots + |a_k - \bar{x}|f_k = \sum_{j=1}^{k}|a_j - \bar{x}|f_j$$

Die mittlere absolute Abweichung kann in derselben Weise alternativ auch vom Median x_{med} berechnet werden.

Empirische Varianz und Standardabweichung

Die ***empirische Varianz*** der Werte $x_1, x_2, \ldots x_n$ ist

$$\tilde{s}^2 = \frac{1}{n}[(x_1 - \bar{x})^2 + \cdots + (x_n - \bar{x})^2] = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

Die ***Standardabweichung*** $\tilde{s}$ ist die Wurzel aus der Varianz, $\tilde{s} = \sqrt{\tilde{s}^2}$.

Für die Häufigkeitsdaten gilt

$$\tilde{s}^2 = (a_1 - \bar{x})^2 f_1 + \cdots + (a_k - \bar{x})^2 f_k = \sum_{j=1}^{k}(a_j - \bar{x})^2 f_j$$

Stichprobenvarianz

Die Varianz wird oft auch als

$$\tilde{s}^2 = \frac{1}{n-1}[(x_1-\bar{x})^2+\cdots+(x_n-\bar{x})^2] = \frac{1}{n-1}\sum_{i=1}^{n}(x_i-\bar{x})^2$$

definiert (wir teilen durch n–1 anstatt durch n), was man als ***Stichprobenvarianz*** bezeichnet.

Statistiksoftware wie R berechnet diese Variante. Sie leitet sich aus dem stochastischen Konzept eines „erwartungstreuen Schätzers“ ab.

Je größer n, desto kleiner ist der Unterschied.

Verschiebungssatz

Mit arithmetischem Mittelwert $\bar{x}$ gilt für die Varianz

$$\tilde{s}^2 = \frac{1}{n} \sum_{i=1}^{n} x_i{}^2 - \bar{x}^2$$

Dies folgt aus dem Verschiebungssatz

$$\sum_{i=1}^{n} (x_i - c)^2 = \sum_{i=1}^{n} (x_i - \bar{x})^2 + n(\bar{x} - c)^2$$

Variationskoeffizient

Bei einigen Anwendungen würde man eine wachsende Varianz bei wachsenden Werten und dementsprechend wachsendem Mittelwert erwarten.

Um die Streuung verschiedener Messungen vergleich zu können, kann man dann bei positiven Ausprägungen und einem positiven Mittelwert den Variationskoeffizienten v benutzen:

$$v = \frac{\tilde{s}}{\bar{x}},\ \bar{x} > 0$$

Quiz I

Sie verdoppeln die Miete aller Berliner Wohnungen.

Wie verändert sich das arithmetische Mittel der Mieten?

A: Es bleibt gleich

B: Es wird größer, aber man weiß nicht wie viel

C: Es verdoppelt sich

D: Kann man nicht sagen

Quiz II

Sie erhöhen die Miete aller Berliner Wohnungen um €100.

Wie verändert sich das arithmetische Mittel der Mieten?

A: Es bleibt gleich

B: Es wird größer, aber man weiß nicht wie viel

C: Es erhöht sich um €100

D: Kann man nicht sagen

Quiz III

Sie verdoppeln die Miete aller Berliner Wohnungen.

Wie verändert sich der Median der Mieten?

A: Er bleibt gleich

B: Er wird größer, aber man weiß nicht wie viel

C: Er verdoppelt sich

D: Kann man nicht sagen

Quiz IV

Sie erhöhen die Miete aller Berliner Wohnungen um €100.

Wie verändert sich der Median der Mieten?

A: Er bleibt gleich

B: Er wird größer, aber man weiß nicht wie viel

C: Er erhöht sich um €100

D: Kann man nicht sagen

Transformationsregel für arithmetisches Mittel und Varianz

Für $y_i = a \cdot x_i + b$ mit $i \in \{1, 2, \ldots n\}$ ist

$$\bar{y} = a \cdot \bar{x} + b$$

$$\tilde{s_y}^2 = a^2 \cdot \tilde{s_x}^2$$

$$\tilde{s_y} = |a| \cdot \tilde{s_x}$$